RWE Analytics Dossier

Camada analítica e epidemiológica sobre OMOP CDM

RWE Analytics Dossier — Camada Analítica e Científica sobre OMOP CDM

Elaborado na perspetiva de Senior Health Data Scientist / Lead Epidemiologist

Objetivo: demonstrar capacidade de desenhar e executar RWE studies — não de construir pipelines

---

0. DIAGNÓSTICO ESTRATÉGICO — O ELEFANTE NA SALA

Antes de recomendar um único estudo, tenho de resolver a questão que um Lead Epidemiologista coloca nos primeiros 90 segundos e que decide a entrevista: **N = 50 e N = 58.**

0.1 O que os números dizem (calculados para os teus dados reais)

Projeto A — 50 doentes, ~25 por braço, 70 dias de seguimento

Risco basal	RR a detetar	Potência
20%	2.0	**33%**
20%	2.5	61%
20%	3.0	85%
30%	2.0	**57%**
10%	2.0	**17%**

RR mínimo detetável a 80% de potência, n=25/braço:

Risco basal	RR mínimo
10%	**4.44**
20%	**2.89**
30%	**2.29**

E ao nível do teste exato de Fisher (que é o que deves usar, não o qui-quadrado, porque as contagens esperadas são < 5):

Tabela (a/25 vs c/25)	p (bicaudal exato)
5 vs 0	0.050
6 vs 0	0.022
7 vs 1	0.049
8 vs 2	0.074
10 vs 3	0.051

Conclusão brutal e incontornável: para obteres um $p < 0.05$ no Projeto A precisas de algo como **7 eventos num braço contra 1 no outro**. Um ensaio de 70 dias não produz efeitos de RR ≈ 3 em segurança. **O Projeto A não suporta inferência comparativa. Ponto.**

Isto não é uma fraqueza — **é a tua oportunidade de demonstrar julgamento.** O candidato medíocre esconde o N e apresenta p-values. O candidato sénior diz:

> "Com 25 doentes por braço tenho 33% de potência para detetar um RR de 2.0 num risco basal de 20%. O RR mínimo detetável a 80% de potência é 2.9. Portanto **não** vou usar o Projeto A para fazer

> descoberta — vou usá-lo para fazer **validação metodológica**: replicar em OMOP um estimando cujo valor-verdadeiro eu já conheço do ADaM, e medir a concordância. É o único desenho em que N=50 é cientificamente suficiente, porque o desfecho não é um efeito clínico — é a exatidão da minha reimplementação."

Projeto B — 58 doentes, mas 26 anos, 16.000 medições

Recurso	Valor
Pessoas-ano disponíveis	**1.508**
Medições por doente	**276**
Densidade	**10.6 medições/doente-ano**

Aqui a história muda completamente. **N=58 é pequeno para desenho entre-pessoas, mas 1.508 pessoas-ano e 16.000 medições são substanciais para desenho intra-pessoa.**

RR detetável a 80% de potência num Self-Controlled Case Series (Var(log ψ) ≈ 1/n_exposto + 1/n_não-exposto):

% de pessoa-tempo exposto	50 eventos expostos	100	250
10%	**1.52**	1.34	—
25%	1.91	1.51	**1.34**

Ou seja: **com 50 eventos ocorridos em tempo exposto, um SCCS deteta RR ≈ 1.5.** Isso é uma magnitude de efeito perfeitamente plausível em segurança de fármacos.

Precisão de uma proporção com n=58: um IC 95% (Wilson) em torno de p̂=0.25 tem largura de **± 11 pontos percentuais**. Reporta isso. Nunca reportes "ns".

0.2 A tese central de todo o teu posicionamento

> **O teu deliverable não é "resultados estatisticamente significativos". É "uma implementação metodologicamente completa, pré-especificada e portável, que correria inalterada contra uma coorte de 2 milhões de doentes".**

Isto é literalmente o que uma empresa em redes federadas (EHDEN / DARWIN EU) compra: **código que é o mesmo em todos os nós, e cuja correção metodológica é auditável independentemente do tamanho da amostra local.** Ninguém na rede consegue ver os dados dos outros — por isso a única coisa que viaja entre nós é **o código e a especificação**. Demonstrar que percebes isso coloca-te automaticamente do lado de dentro.

E há um segundo corolário igualmente forte:

> **A amostra pequena não é um obstáculo à demonstração de rigor metodológico — é o seu ambiente ideal.** Com N=50, qualquer erro de especificação é visível. Com N=2.000.000, um erro de especificação produz uma estimativa precisa e errada, e ninguém o deteta.

---

1. PROJETO A — Ensaio Clínico em OMOP (origem CDISC SDTM)

1.1 O que o Projeto A é e não é

O Projeto A NÃO serve para	O Projeto A SERVE para
Comparar braços com significância estatística	**Replicar** estimandos conhecidos e medir concordância

O Projeto A NÃO serve para	O Projeto A SERVE para
Gerar evidência clínica nova	**Validar a tradução CDISC → OMOP** na única moeda que importa: o estimando
Análise de subgrupos	Demonstrar mecânica de coorte (índice, washout, TAR, atrição)
Modelação multivariável	Demonstrar farmacovigilância estruturada (eDISH, Hy's Law)

1.2 Estudo A1 — ★ ESTUDO DE REPLICAÇÃO / RECONCILIAÇÃO (o carro-chefe)

Desenho: cross-validation metodológica. O ADaM do Projeto C é o ground truth regulamentar. Reimplementas o mesmo estimando em OMOP SQL e comparas **doente a doente**.

Estimandos a replicar (3, escolhe por ordem de valor):

- `TRTEMFL` **(treatment-emergent flag)** — o AE só é emergente se `AESTDTC` ≥ data de início de tratamento. Em OMOP: evento em `CONDITION_OCCURRENCE` (domínio AE via `source_record_lineage`) com data ≥ data de início da `DRUG_ERA` do fármaco do estudo (domínio EX).
- **Tempo até ao primeiro AE** (`ADTTE`: `AVAL`, `CNSR`) — em OMOP: índice = 1ª exposição EX; TAR até primeiro evento AE; censura no fim do `OBSERVATION_PERIOD` ou fim de estudo.
- **Baseline e change-from-baseline** (`ADLB`: `ABLFL`, `BASE`, `CHG`) — em OMOP: baseline = última medição LB na janela pré-índice; CHG = valor pós — BASE.

Métricas de concordância (a escolha certa para cada tipo):

Estimando	Métrica de concordância
`TRTEMFL` (binário)	Concordância bruta % + **κ de Cohen** (e reporta o paradoxo de κ se a prevalência for extrema)
Tempo até evento (contínuo censurado)	**Diferença em dias por sujeito** → mediana, IQR, e **Bland-Altman** (viés e limites de concordância)
`BASE` / `CHG` (contínuo)	**ICC(2,1)** de concordância absoluta + **Bland-Altman** (não uses correlação de Pearson — correlação mede associação, não concordância!)
`CNSR` (binário)	Concordância % + κ

Output obrigatório: tabela de **discordâncias com root cause**. Cada sujeito discordante recebe uma classificação: diferença de janela de baseline / diferença de regra de censura / evento fora do observation period / domínio mal atribuído / erro de mapeamento de conceito. **Esta tabela é o entregável mais valioso de todo o teu portfolio** — prova que sabes depurar uma semântica, não apenas escrever SQL.

[!] Armadilha crítica que deves dominar e mencionar:

Em OMOP, **AE e MH vivem ambos em** `CONDITION_OCCURRENCE`, e no teu pipeline ambos têm `condition_type_concept_id = 32809` (Case Report Form). **O CDM standard não distingue evento adverso de historial médico.** A única forma de os separar é a tua `source_record_lineage.source_domain` ('AE' vs 'MH').

Diz isto na entrevista, textualmente:

> "Um dos primeiros problemas reais que encontrei: o OMOP não tem um tipo de conceito que separe 'adverse event' de 'medical history'. Ambos são condições, ambos vindos de eCRF, ambos 32809. Se eu fizesse uma coorte de 'doentes com hipertensão' sobre o Projeto A sem filtrar por `source_domain`, estava a contar historial médico basal como se fosse evento emergente — e a inflacionar o braço ativo, porque quem tem mais comorbilidade basal também tem mais historial registado. **É um viés de confundimento por indicção criado puramente pelo modelo de dados.** Resolvi com proveniência ao nível do registo, e é por isso que `source_record_lineage` não é um extra de compliance: é um requisito de validade interna do estimando."

Isto é uma resposta de sénior. Nenhum candidato júnior chega lá.

1.3 Estudo A2 — Análise de Segurança / Farmacovigilância Estruturada

Pergunta clínica: qual o perfil de eventos adversos emergentes por braço, expresso como incidência sobre pessoa-tempo?

Métricas:

- **Taxa de incidência (IR)** = eventos / pessoas-tempo em risco, por braço, com **IC 95% exato de Poisson** (não normal — com ~20 eventos, a aproximação normal é má)
- **Razão de taxas de incidência (IRR)** com IC pelo **método exato condicional de Poisson** (condicional na soma de eventos)
- **Risco cumulativo** por braço com **IC de Clopper-Pearson** (nunca Wald — com n=25 o Wald produz limites negativos)
- **Diferença de risco** com IC de **Newcombe** (híbrido de Wilson) — melhor cobertura que Wald em amostras pequenas

Estrutura por órgão e sistema (SOC): atenção — **MedDRA não é vocabulário standard no OMOP** por defeito. Tens de:

- Agrupar por `SNOMED` ancestor em `CONDITION_OCCURRENCE`, ou
- Ter conceitos MedDRA como não-standard ligados por `Maps to`, e navegar via `CONCEPT_RELATIONSHIP`.

Diz que sabes disto — é um detalhe que separa quem usou OMOP de quem leu sobre OMOP.

★ O gráfico que te diferencia: eDISH plot

Para hepatotoxicidade tens LB com ALT, AST e bilirrubina. Constrói um **eDISH plot** (evaluation of Drug-Induced Serious Hepatotoxicity), que é o gráfico padrão da FDA/EMA para sinalização de lesão hepática induzida por fármaco:

- Eixo X: **pico de ALT** (em múltiplos do limite superior do normal, LSN)
- Eixo Y: **pico de bilirrubina total** (em múltiplos do LSN)
- **Escala logarítmica dupla**, com linhas em ×1 e ×3 (ALT) e ×1.5 e ×2 (BT)
- Quadrante superior direito = **sinal de Hy's Law**

Regra de Hy's Law (critério regulamentar real):

```
ALT (ou AST) > 3 × LSN
    E
Bilirrubina total > 2 × LSN
    E
Sem evidência de colestase (ALP > 2 × LSN exclui)
    E
Sem outra causa identificável
→ risco ~10% de falência hepática. É o sinal de segurança mais grave em desenvolvimento de
    fármacos.
```

Como obter o LSN: o `MEASUREMENT` do OMOP v5.4 tem `range_high` / `range_low`. Se o teu LB os tiver (verifica!), usa-os — é a forma correta. Se não, declara que estás a usar um LSN fixo da literatura e marca como limitação. **Nunca inventes silenciosamente.**

Com N=50 não vais encontrar um caso de Hy's Law — e deves dizê-lo. O valor do eDISH plot aqui é **demonstrar que sabes construir o instrumento de farmacovigilância regulamentar**, não encontrar o sinal.

1.4 Estudo A3 — Tempo até ao Primeiro Evento Adverso (sobrevivência)

Definição operacional em OMOP:

Elemento	Especificação
Evento índice	Data da primeira `DRUG_EXPOSURE` com domínio EX (via `source_record_lineage`)
População elegível	Doentes com ≥1 exposição EX e ≥1 dia de seguimento após o índice
Time-at-risk (TAR)	Dia (índice + 1) → primeiro evento AE / censura
Censura	Fim do `OBSERVATION_PERIOD`, fim do estudo, ou perda de seguimento
Desfecho	1º `CONDITION_OCCURRENCE` com `source_domain = 'AE'`

Análise:

- **Kaplan-Meier** por braço com **IC de Hall-Wellner** (bandas de confiança simultâneas) e **número-em-risco** sob o eixo (obrigatório — ausência disso é erro de principiante)
- **Log-rank** para comparação — com declaração explícita de que a potência é ~0
- **Cox proporcional**: [!] **regra dos 10 eventos por variável (EPV)**. Com ~20 eventos, podes ajustar no máximo 1–2 covariáveis. Se precisares de mais, usa **regressão de Cox penalizada (Firth)** ou **propensity score como única covariável**. Declarar isto mostra que percebes a diferença entre "correr um modelo" e "especificar um modelo".
- Reportar **HR com IC 95%** e **explicitar a largura do intervalo como o resultado principal** — com n=50 o IC vai ser largo, e a tua conclusão é "imprecisão", não "ausência de efeito"

> **Erro clássico a evitar em voz alta:** "O HR foi 1.4 (IC 95%: 0.5–3.9), portanto não há diferença entre braços." **Errado.** O correto é: "O intervalo inclui desde uma redução de 50% até um aumento de quase 4×; este estudo não tem precisão para distinguir essas hipóteses, e a conclusão apropriada é que o efeito permanece indeterminado, não que é nulo."

1.5 Estudo A4 — Trajetórias Laboratoriais Longitudinais (ALT/AST, glicose, PA)

Pergunta clínica: os braços divergem na trajetória de segurança hepática / metabólica ao longo do ensaio?

Especificação de baseline — regra crítica:

```
Baseline = valor da medição MAIS PRÓXIMA antes do índice,
           dentro de uma janela pré-especificada (ex.: D-7 a D-1)
NÃO uses "a primeira medição do doente"
```

Porquê: "primeira medição" mistura basais medidos a 6 meses com basais medidos no dia anterior, e introduz viés de tempo dependentemente do braço com visitas mais frequentes. **Reporta quantos doentes ficaram sem baseline na janela** — a atrito do baseline é um resultado em si.

Modelos:

Opção	Quando	Especificação
ANCOVA em change-from-baseline	1 medição pós-basal	`CHG ~ BASE + braço` — ajustar pela baseline reduz variância e é o padrão regulamentar
Modelo misto (MMRM-lite)	medições repetidas	Intercepto aleatório + declive aleatório por doente; `valor ~ tempo*braço + BASE + (tempo|person_id)`
GEE	se quiseres efeito populacional médio	Matriz de correlação AR(1) ou exchangeable

Declara em voz alta: "Prefiro modelo misto a GEE aqui porque quero a estrutura de variância entre-doentes para além do efeito médio, e porque o modelo misto lida melhor com medições em tempos irregulares — o que é a norma em dados reais."

Análise de hepatotoxicidade em categorias pré-especificadas (não só contínua):

```
ALT > 3 × LSN   (sinalização)
ALT > 5 × LSN   (sinalização moderada)
ALT > 10 × LSN  (sinalização grave)
ALT > 3 × LSN E BT > 2 × LSN   (Hy's Law)
```

1.6 Estudo A5 — Utilização de Medicação Concomitante e de Resgate

[!] Corrige primeiro: o teu `src/analytics/rwe_queries.py` **usa** `LOWER(c.concept_name) LIKE '%acetaminophen%'`**.** Isto é um **anti-padrão de fenotipagem** e deves eliminá-lo, por três razões demonstráveis:

- Falha para nomes comerciais (Tylenol, Panadol, Ben-u-ron) e para o princípio ativo europeu (**paracetamol**)
- Apanha falsos positivos em nomes compostos (ex.: combinações codeína/paracetamol contam como paracetamol — e depois não sabes se foi prescrito como analgésico ou como adjuvante)
- Não reutilizável entre nós: em Espanha é paracetamol, em França paracétamol — **o código literal não viaja na rede federada**

Substituição correta:

```
-- Concept set declarativo: "Acetaminophen/Paracetamol (ingrediente)"
WITH exposure_ingredient AS (
  SELECT DISTINCT de.person_id, de.drug_exposure_id, de.drug_exposure_start_date,
         ca.ancestor_concept_id AS ingredient_concept_id
  FROM drug_exposure de
  JOIN concept_ancestor ca
    ON ca.descendant_concept_id = de.drug_concept_id
  WHERE ca.ancestor_concept_id IN (1125315)   -- acetaminophen, RxNorm ingredient
    AND de.drug_concept_id <> 0
)
```

E **usa o** `CONCEPT_ANCESTOR` **para expandir a partir do ingrediente**, não o nome. Um concept set é um **artefacto versionado**, uma string SQL não.

Definição de "resgate" (medicação de resgate é um endpoint clínico):

- **Uso incidente** após o índice — não uso prevalente. Exclui quem já tomava antes.
- Métricas: proporção de doentes com ≥1 uso (com IC de Wilson), e taxa de utilizações por pessoa-tempo
- **Análise de sensibilidade:** gap allowance de 30 / 60 / 90 dias para definir episódio

1.7 Estudo A6 — Demonstração de New-User Design (mesmo dentro do ensaio)

Mesmo num ensaio, demonstra a mecânica que vais usar em RWD — é isto que o entrevistador quer ver:

Elemento	Especificação no Projeto A
Evento índice	1ª exposição ao tratamento do estudo (domínio EX)
Período de washout / lookback	Exigir X dias de observação contínua antes do índice **sem** exposição prévia ao fármaco
Critérios de inclusão	≥1 dia de TAR; idade ≥18; medição basal disponível
Critérios de exclusão	Doença hepática prévia (MH domain); ALT basal > 3× LSN
Saída de coorte	Fim do `OBSERVATION_PERIOD`, fim do estudo, ou evento
Time-at-risk	Dia 1 → evento / censura (**justifica o dia 1** vs dia 0)

Dia 0 vs dia 1 — o detalhe que distingue: começar o TAR no dia 0 inclui o dia do índice, onde o evento não pode ser causado pela exposição mas pode estar associado a ela (viés de depleção de suscetíveis / protopático). **Pré-especifica e justifica.** A OHDSI tem uma convenção e tu deves segui-la e declará-la.

Entregável obrigatório: TABELA DE ATRIÇÃO.

---

2. PROJETO B — EHR Longitudinal em OMOP (origem FHIR, 26 anos)

2.1 O que o Projeto B permite que o A não permite

Com 1.508 pessoas-ano e 16.000 medições, o Projeto B suporta **desenhos intra-pessoa**. A intuição estatística que deves articular:

> **Num desenho entre-pessoas, a precisão é governada por N (58). Num desenho intra-pessoa, é governada pelo número de eventos e pela pessoa-tempo (1.508 anos). O mesmo N=58 é subpotente para o primeiro e perfeitamente viável para o segundo — desde que eu use um modelo que compare o doente consigo próprio.**

Isto é o tipo de raciocínio que um epidemiologista sénior reconhece imediatamente.

2.2 Estudo B1 — ★ CASCATA DE FENÓTIPOS COM `CONCEPT_ANCESTOR` (o carro-chefe)

[!] Corrige primeiro: `src/analytics/rwe_cohort_discovery.py` usa `condition_concept_id = 320128`. **Fenotipagem por conceito único é o erro mais comum e mais grave em RWE** — apanha apenas o código exato "Essential hypertension" e perde todos os descendentes SNOMED (hipertensão maligna, hipertensão sistólica isolada, etc.). O mesmo anti-padrão está no `text_to_sql_agent.py` com `ILIKE '%covid%'`.

A correção é o teu deliverable mais alto-valor.

Constrói 4 definições aninhadas e compara o rendimento:

Definição	Regra	Propósito
P1	≥1 código descendente de 320128	Sensibilidade máxima, especificidade mínima
P2	≥2 códigos em **datas distintas** (≥1 dia de separação)	Remove registos de "regra de exclusão" e suspeita descartada
P3	P2 **E** ≥1 fármaco anti-hipertensor (ancestor RxNorm: diuréticos, IECA, ARA II, β-bloqueadores, CCB)	Aumenta especificidade — triangula diagnóstico com tratamento
P4	P3 **E** ≥1 medição de PA ≥140/90	Fenótipo clínico estrito

Especificação técnica do ancestor:

```
-- Concept set: "Hypertension (SNOMED descendants)"
SELECT DISTINCT co.person_id, co.condition_start_date
FROM condition_occurrence co
JOIN concept_ancestor ca
  ON ca.descendant_concept_id = co.condition_concept_id
WHERE ca.ancestor_concept_id = 320128
  AND co.condition_concept_id <> 0
  -- controla granularidade:
  AND ca.min_levels_of_separation >= 0
```

Detalhes de `CONCEPT_ANCESTOR` que deves mencionar (são testes clássicos):

- `min_levels_of_separation` / `max_levels_of_separation` controlam profundidade — útil para excluir o próprio conceito raiz ou para limitar granularidade excessiva
- **Um conceito pode ter múltiplos caminhos até um ancestor** → usa `SELECT DISTINCT` sempre, senão duplicas registos e inflacionas contagens
- **Não uses** `concept_ancestor` **para saltar domínios** — a hierarquia é intra-vocabulário
- Preferência por conceitos **standard** (`standard_concept = 'S'`) e **não expirados**

Output — análise de sensibilidade do fenótipo:

```
Definição   N doentes   %
P1          34          58.6%
P2          27          46.6%
P3          22          37.9%
P4          15          25.9%
```

Depois: **matriz de sobreposição (índice de Jaccard)** entre definições, e — o passo que quase ninguém dá — **reestima o desfecho primário sob cada definição de fenótipo e mostra como a estimativa se move.**

> "A pergunta não é 'qual é o fenótipo correto'. É 'quão sensível é a minha estimativa à escolha do fenótipo'. Se o RR passa de 1.8 para 1.1 conforme endureço a definição, o resultado não é robusto — e é essa informação que eu entrego ao cliente, não um único número."

Isto é, literalmente, o trabalho de um epidemiologista sénior numa rede federada.

2.3 Estudo B2 — Perfil de Observabilidade da Base de Dados (Achilles-style)

Antes de qualquer estimativa, caracteriza. **A pergunta que a rede federada faz primeiro é de viabilidade, não de efeito.**

Entregáveis:

- Distribuição de `OBSERVATION_PERIOD` (duração mediana, percentis, por doente)
- Idade na primeira observação e no índice
- **Densidade de dados por domínio por ano-calendário** — gráfico essencial
- Densidade de medições por doente-ano (10.6 no teu caso)
- Proporção de `concept_id = 0` por domínio e por ano (**cobertura de mapeamento ao longo do tempo**)

O conceito metodológico que deves nomear: viés de observação informativa (informative observation bias).

> "Com 26 anos de seguimento, a densidade de medições não é constante — aumenta quando o doente está doente. Se eu estimar incidência de diagnóstico sem modelar a intensidade de contacto com o sistema de saúde, estou a medir utilização de cuidados, não doença. Por isso começo sempre por um perfil de observabilidade, e é por isso que o Achilles existe antes do CohortMethod."

▸ Dica prática de alto valor: corre o ACHILLES nativamente sobre o teu DuckDB

Já tens `DatabaseConnector 7.2.0` no `renv.lock` e **já provaste que funciona** — o teu `run_dqd_worker.R` usa `createConnectionDetails(dbms = "duckdb", server = db_path)`.

Podes por isso correr, **sem reescrever uma linha de SQL**:

Pacote OHDSI	O que te dá
Achilles	Caracterização completa + Achilles Heel report (data quality)
CohortGenerator	Coortes em SQL gerado a partir de definições declarativas

Pacote OHDSI	O que te dá
CohortDiagnostics	Diagnóstico de coorte, covariáveis, tabelas de atrição, **balancedade de covariáveis (SMD)**
IncidencePrevalence	Incidência e prevalência com denominação correta de pessoa-tempo
Characterization	Tabelas de caracterização comparativas

Cuidados: `SqlRender` precisa de traduzir para DuckDB (usa `translate()`); define `resultsDatabaseSchema = "main"`; define `numThreads = 1` (o DuckDB é single-writer).

> **Se fizeres isto, passas a ter outputs em formato OHDSI-standard — que é o formato que uma empresa da rede reconhece à primeira vista.** É o atalho mais eficiente que existe entre o teu portfolio e a linguagem nativa deles.

2.4 Estudo B3 — Persistência e Adesão Terapêutica (26 anos)

Endpoints RWE clássicos, alto valor comercial para pharma:

Métrica	Definição
Persistência	Tempo desde início até descontinuação (gap > X dias sem cobertura). Analisar por **Kaplan-Meier** com IC
PDC (Proportion of Days Covered)	dias cobertos / dias no intervalo de seguimento
MPR (Medication Possession Ratio)	soma de dias de fornecimento / dias no intervalo
Taxa de abandono precoce	Proporção que descontinua nos primeiros 90 dias

Especificações críticas:

- **Gap allowance pré-especificado** (30 / 60 / 90 dias) com **análise de sensibilidade obrigatória** — a escolha do gap move a estimativa significativamente
- **Reconstrução de eras:** podes usar `DRUG_ERA` (já tens derivação com gap de 30 dias) ou reconstruir a partir de `DRUG_EXPOSURE` com o teu gap
- **Censura administrativa:** usa `OBSERVATION_PERIOD` para definir o denominador; **nunca** contes dias fora do período de observação
- **Índice de medicação (medication possession index) **vs** sobreposição** — declara qual usas

[!] Viés a nomear: o viés de prevalent user. Se incluíres doentes já em tratamento no índice, a tua coorte é selecionada para tolerância ao fármaco e a persistência observada será artificialmente alta. **Exige new-user com washout.** (Tens em `CDISC-to-OMOP` a noção de fim administrativamente censurado vs registado na fonte — transporta essa ideia para cá.)

2.5 Estudo B4 — Trajetórias Longitudinal de Biomarcadores (modelos mistos)

Com 276 medições por doente, isto é estatisticamente viável — ao contrário do Projeto A.

Modelo:

```
valor ~ tempo(idade) * exposição + covariáveis + (1 + tempo | person_id)
        ↑ declive aleatório por doente
```

Elementos obrigatórios:

- **Escala de tempo:** usar **idade** e não "dias desde o índice" para trajetórias de vida — escolhe e justifica

- **Decomposição within-person vs between-person** — o ponto metodológico mais importante aqui: `` `X_ij = média_do_doente_i (between) + (X_ij − média_do_doente_i) (within)` `` Incluir ambas no modelo: o coeficiente within é o efeito intra-pessoa (não confundido por características fixas), o between é a comparação transversal (confundida). **A diferença entre os dois é um diagnóstico de confundimento** — e é exatamente a falácia ecológica evitada.
- **Estrutura de variância:** compara intercepto aleatório vs intercepto+declive aleatório por **LRT (teste de razão de verossimilhanças) com correção de boundary** (o LRT para variância = 0 é conservador — usa a mistura χ^2_0/χ^2_1, não χ^2_1)
- **Heterogeneidade:** reporta a **variância dos declives aleatórios** — mostra que há respondedores e não-respondedores

Exemplos clínicos concretos:

- **Declínio de eGFR** por ano de idade, estratificado por exposição a IECAs / AINEs
- **Trajetória de PA sistólica** antes e depois do início de anti-hipertensor
- **Trajetória de HbA1c / glicose** em doentes com diagnóstico de diabetes
- **Trajetória de LDL** sob estatina

2.6 Estudo B5 — ★ SELF-CONTROLLED CASE SERIES (SCCS)

Este é o método mais sofisticado que podes apresentar — e é adequadíssimo ao teu N=58 com 26 anos.

Porquê: o SCCS compara **cada doente consigo próprio** em períodos expostos vs não expostos. Portanto **controla automaticamente todos os confundidores invariantes no tempo** — genética, estatuto socioeconómico, comorbilidade basal, estilo de vida. Numa base de 58 doentes, é a diferença entre um desenho impossível e um desenho viável.

Requisitos (tens todos):

- [OK] Eventos recorrentes ou únicos com data (`CONDITION_OCCURRENCE`)
- [OK] Períodos de exposição com datas (`DRUG_EXPOSURE`)
- [OK] Período de observação bem definido (`OBSERVATION_PERIOD`, 26 anos)

Potência (calculada para os teus dados):

Eventos em tempo exposto	RR detetável (80% potência)
25	1.78 – 1.91
50	**1.50 – 1.52**
100	1.34

Exemplos clínicos de aplicação:

- AINE → hemorragia gastrointestinal
- Antibiótico → lesão hepática aguda
- Estatina → miopatia / CK elevada
- Anti-hipertensor → lesão renal aguda
- (Exemplo clássico OHDSI: vacina → evento adverso)

Assunções que tens de declarar explicitamente (isto é o que o entrevistador vai testar):

- **Os eventos devem ser recorrentes** (ou usar a variante para evento único)
- **A ocorrência de um evento não deve afetar a probabilidade de exposição subsequente** — se o doente teve AINE suspenso após hemorragia, viola-se a assunção. Mitigação: **período de pré-exposição / *pre-exposure risk window*** ou exclusão do tempo após o evento
- **A exposição não deve afetar a observação** — se o fármaco aumenta contacto com o sistema de saúde, há viés de deteção
- **Os eventos devem ser independentes entre si** — ou usar variante com ajuste de dependência

[!] A armadilha clássica que deves mencionar: o SCCS é vulnerável ao **viés de indicação dependente do tempo**. Exemplo perfeito: prescreves AINE a quem tem dor; a dor pode ser o primeiro sintoma do evento. **A janela de risco começa antes do evento por construção, não por causalidade.** Mitigação: análise de sensibilidade com **período de pré-exposição** e com **janelas de risco deslocadas**.

2.7 Estudo B6 — Carga de Multimorbilidade (Charlson / Elixhauser)

Alinhamento direto com Value-Based Healthcare — que o teu entrevistador mencionou.

Implementação: scores via `CONCEPT_ANCESTOR` sobre `CONDITION_OCCURRENCE` — cada componente do Charlson é um concept set com descendentes.

Especificações:

- **Janela de baseline** pré-índice (ex.: 365 dias, ou todo o historial)
- **Versões:** Charlson original, Charlson adaptado (Quan et al., 2011 — a versão ICD-9/10 é a referência), **Elixhauser** (AHRQ)
- **Peso:** reporta score ponderado **e** contagem simples de condições — comportam-se de forma diferente
- **Evolução temporal:** score basal, score no índice, e **delta** — a trajetória de multimorbilidade é mais informativa que o valor pontual

Output com valor para VBHC: estratificação da coorte por carga de comorbilidade e descrição de utilização de cuidados por estrato.

2.8 Estudo B7 — ★ Diagnóstico de Coorte com Outcomes de Controlo Negativo (NCO)

Isto é topo de gama metodológico OHDSI (Schuemie et al., empirical calibration). Muitos epidemiologistas seniores não o aplicam — se o referires com propriedade, ficas posicionado acima da linha de água.

O princípio: escolhes desfechos que **não podem** ser causados pela exposição (ex.: exposição a estatina → fratura de fémur por acidente de viação; ou exposição a anti-hipertensor → diagnóstico de miopia). Se o teu desenho produz RR ≠ 1 para esses desfechos, **o teu desenho está enviesado** — não o teu fármaco.

O que fazes:

- Define 20–50 NCO plausíveis
- Corre o **mesmo** código de estimação sobre todos
- Constrói a **distribuição empírica dos RR dos NCO**
- Se o RR verdadeiro do desfecho de interesse cai dentro dessa distribuição, **não é um sinal** — é ruído de sistema
- **Calibra** o teu IC usando a distribuição nula empírica

Porquê em redes federadas isto é crítico: não podes ir ver os dados. Precisas de um **diagnóstico interno que detete viés sem inspeção visual**. O NCO é exatamente isso. Diz isto — é uma resposta de quem pensa em escala de rede.

2.9 Estudo B8 — Medicamentos e PROMs (ICHOM / Value-Based Healthcare)

O entrevistador mencionou ICHOM/PROMs. Prepara isto:

Onde vivem os PROMs no OMOP: tipicamente em `OBSERVATION` (instrumentos validados como conceitos standard), por vezes em `MEASUREMENT`. Há trabalho ativo na comunidade OHDSI sobre

representação de questionários.

Estudo concreto: trajetória longitudinal de um PROM (ex.: dor, função física, qualidade de vida) em doentes com condição crónica, antes/depois de início de tratamento.

[!] O problema metodológico real que deves nomear — e que é o que um VBHC shop enfrenta todos os dias:

> "O problema dos PROMs em dados rotineiros não é a medição, é a **ausência informativa**. O PROM é preenchido quando o doente vai à consulta — ou seja, quando está pior. **Os dados em falta são MNAR** (missing not at random), e uma análise complete-case enviesa sistematicamente para doentes mais graves. Não resolves isto com imputação múltipla — resolves declarando o mecanismo, fazendo análise de sensibilidade com pattern-mixture models ou delta adjustment, e reportando a proporção de missingness por braço como um resultado de viabilidade, não como uma nota de rodapé."

Isto responde diretamente ao "ICHOM/PROMs" que ele mencionou e mostra que pensaste no problema real, não no diagrama.

---

3. METODOLOGIA OHDSI/OMOP — COMO ESTRUTURAR AS QUERIES

3.1 A anatomia de uma coorte OHDSI (completa)

Elemento	Especificação	Onde vive no CDM
Evento índice	Data do primeiro evento qualificador	Qualquer tabela clínica
Período de lookback / washout	Dias de observação contínua antes do índice sem o critério de exclusão	`OBSERVATION_PERIOD`
Critérios de inclusão	Aplicados em **sequência ordenada**	Vários
Critérios de exclusão	Aplicados em **sequência ordenada**	Vários
Entrada na coorte	`cohort_start_date` = data do índice	—
Saída da coorte	`cohort_end_date` = mínimo(fim OP, evento, fim de estudo, desfecho)	`OBSERVATION_PERIOD`
Time-at-risk	Dia 0 ou dia 1 → desfecho / censura	Derivado

Estrutura de tabela de coorte (formato CohortGenerator — usa exatamente esta):

```
cohort_definition_id | subject_id | cohort_start_date | cohort_end_date
```

3.2 Tabela de atrição — o entregável obrigatório

Toda a coorte OHDSI produz uma tabela de atrição. É o artefacto que permite a outro investigador (ou a um regulador) ver exatamente quantos doentes foram perdidos em cada regra e porquê.

```
Regra                                              Doentes   Eventos   Únicos
1.  População inicial                                 58      16.000     58
2.  ≥365 dias de observação antes do índice           54      15.200     54
3.  Sem exposição prévia ao fármaco (washout)         41      11.800     41
4.  Idade ≥18 no índice                               41      11.800     41
5.  Sem critério de exclusão (doença terminal)        39      11.100     39
6.  ≥1 dia de time-at-risk                            38      10.900     38
──────────────────────────────────────────────────────────────────────────
COORTE FINAL                                          38      10.900     38
```

Porquê é inegociável: numa rede federada, a tabela de atrição é **a única forma de comparar coortes entre nós sem ver os dados**. Se o nó A retém 90% e o nó B retém 40% na mesma regra, há uma diferença real de captação de dados — e tu detetas isso sem mover um registo. **Diz isto na entrevista.**

3.3 Concept sets como artefactos declarativos versionados

Anti-padrão (teu código atual):

```
WHERE condition_concept_id = 320128            -- rwe_cohort_discovery.py
WHERE c.concept_name ILIKE '%covid%'           -- text_to_sql_agent.py
WHERE LOWER(c.concept_name) LIKE '%acetaminophen%'  -- rwe_queries.py
```

Padrão correto — concept set em JSON (formato de exportação do Atlas):

```
{
  "id": 1,
  "name": "Hypertension (SNOMED, all descendants)",
  "expression": {
    "items": [{
      "concept": { "conceptId": 320128, "conceptName": "Essential hypertension",
                   "domainId": "Condition", "vocabularyId": "SNOMED" },
      "isExcluded": false,
      "includeDescendants": true,
      "includeMapped": false
    }]
  }
}
```

Vantagens:

- [OK] **Versionável** (v1, v2, com SHA-256)
- [OK] **Reutilizável entre estudos e entre nós** — um concept set é um objeto que viaja na rede
- [OK] **Auditável** por um clínico sem ler SQL
- [OK] **Serializável** em SQL gerado automaticamente pelo CohortGenerator/WebAPI

> **Frase para a entrevista:** "Trato um concept set como um artefacto versionado com hash, não como uma cláusula WHERE. É a diferença entre um estudo que outro nó da rede pode executar e um script que só eu percebo."

3.4 Usar `CONCEPT_ANCESTOR` corretamente — os 5 detalhes testáveis

- **Direção:** `ancestor_concept_id = X` → todos os `descendant_concept_id` abaixo de X. É assim que expandes.
- `min_levels_of_separation` / `max_levels_of_separation`**:** controlam profundidade. `min = 1` exclui o próprio conceito raiz.
- `SELECT DISTINCT` **obrigatório:** um conceito pode ter múltiplos caminhos até ao mesmo ancestor → sem DISTINCT duplicas registos e inflacionas numeradores. **Erro silencioso clássico.**
- **Não saltes domínios:** a hierarquia é intra-vocabulário. SNOMED → descendentes SNOMED.
- **Filtro de validade:** cruza sempre com `concept.standard_concept = 'S'` e validade temporal. Um descendente expirado não entra.

3.5 Type concepts — o ponto que separa juniores de seniores no TEU Projeto A

O teu `type_concepts.py` documenta:

- `CASE_REPORT_FORM = 32809` → AE, MH, EX, CM, LB, VS, EG, SV
- `STANDARD_ALGORITHM = 32880` → `OBSERVATION_PERIOD`

Consequência metodológica direta:

> Em OMOP, AE e MH partilham `condition_type_concept_id = 32809`. O CDM **não** distingue evento adverso de historial médico. Sem a tua `source_record_lineage`, qualquer coorte de condições no Projeto A **mistura historial basal com eventos emergentes**.

Isto não é um detalhe de implementação — **é uma ameaça à validade do estimando**, porque a prevalência de historial basal está correlacionada com comorbilidade, que por sua vez está correlacionada com a probabilidade de evento. Confundimento por indicação induzido pelo modelo de dados.

3.6 Estrutura de um estudo OHDSI (Hydra / HADES)

Organiza o teu repositório para espelhar a convenção OHDSI:

```
rwe-studies/
├── README.md                    # Protocolo resumido + como reproduzir
├── protocols/
│   └── study-001-*.md           # PROTOCOLO PRÉ-ESPECIFICADO (ver §5.1)
├── conceptSets/
│   ├── cs-0001-hypertension.json
│   ├── cs-0002-ace-inhibitors.json
│   └── MANIFEST.json            # versão + sha256 de cada concept set
├── cohorts/
│   ├── c-0001-new-users-acei.sql
│   └── c-0002-aki-outcome.sql
├── analysis/
│   ├── 01_cohort_build.py       # gera tabela cohort + tabela de atrição
│   ├── 02_characterization.py   # Table 1 com SMD
│   ├── 03_incidence.py
│   └── 04_sccs.py
├── results/
│   ├── attrition_c0001.csv
│   ├── table1.csv
│   └── figures/
└── tests/
    └── test_cohort_contracts.py # testa invariantes, não resultados
```

4. A PONTE CDISC/ADaM ↔ OMOP (Projeto C ↔ Projeto A)

4.1 O deliverable: estudo de reconciliação bidirecional

Já detalhado em §1.2. Aqui fica o **mapeamento conceitual completo** — esta tabela é um artefacto de entrevista por si só:

Conceito CDISC / ADaM	Conceito OMOP equivalente	Nota de tradução
`DM.RFSTDTC` / `DM.RFENDTC`	`OBSERVATION_PERIOD`	Período de referência do estudo → espinha dorsal da coorte
`ADSL.TRTSDT` / `TRTEDT`	`DRUG_ERA` (ou `DRUG_EXPOSURE`)	Era com gap de 30 dias
`ADSL.ITTFL` / `SAFFL`	Critérios de elegibilidade da coorte	População de análise
`AE.AESTDTC` + `TRTEMFL`	`CONDITION_OCCURRENCE` + TAR	[!] Requer `source_domain='AE'`
`MH.MHSTDTC`	`CONDITION_OCCURRENCE`	[!] Mesma tabela — distinguir por linhagem
`ADAE.AOCCFL`	Primeiro evento no TAR	Marca primeiro de muitos
`ADTTE.AVAL` / `CNSR`	TAR + regra de censura	[!] Ver `end_date_derivation` abaixo
`ADLB.ABLFL`	Query de janela de baseline	Regra de proximidade ao índice

Conceito CDISC / ADaM	Conceito OMOP equivalente	Nota de tradução
ADLB.BASE / CHG	Derivado por SQL	Último valor pré-índice na janela
ADLB.LBNRIND	RANGE_HIGH / RANGE_LOW + VALUE_AS_NUMBER	[!] Depende de o LB ter limites de referência
SV (visitas reais)	VISIT_OCCURRENCE	Visitas do protocolo vs visitas de rotina
DS (disposição)	DEATH + VISIT_OCCURRENCE	Causa de fim de seguimento
EX	DRUG_EXPOSURE (domínio EX)	Exposição do estudo
CM	DRUG_EXPOSURE (domínio CM)	Concomitante
LB / VS / EG	MEASUREMENT	[!] Todos na mesma tabela — distinguir por linhagem
ADTTE Kaplan-Meier	KM sobre coorte OMOP	Replicar e comparar

▸ O detalhe de ouro: `end_date_derivation`

O teu `source_record_lineage` tem um campo `end_date_derivation` que distingue:

- **fim registado na fonte** vs
- **fim administrativamente censurado** (ou derivado por convenção)

Isto mapeia literalmente para a especificação de censura em Target Trial Emulation. A pergunta central de qualquer análise de tempo até evento é: este fim de seguimento é um evento, é uma censura administrativa, ou é uma convenção do ETL?

> **Frase para a entrevista:** "O campo de linhagem que mais valor me dá não é o ID do registo de origem — é o `end_date_derivation`. É ele que me diz se um fim de exposição é uma descontinuação real ou um artefacto do ETL. Se eu confundir os dois, censuro mal, e a censura mal especificada produz um viés que nenhum modelo de Cox recupera. Ter essa distinção ao nível do registo é o que permite usar dados de ensaio como se fossem RWD sem perder o estimando regulamentar."

4.2 Como valorizar o duplo domínio — 6 argumentos, por ordem de força

1. Estudos híbridos e braços de controlo externo (o argumento comercial mais forte)

> "Um cliente pharma com um ensaio de braço único precisa de um comparador. O comparador vem de RWD. Mas para correr **o mesmo código analítico** nos dois braços, ambos têm de estar no mesmo modelo de dados. **Se eu não consigo pôr o ensaio em OMOP, o estudo híbrido não é possível — só posso comparar números publicados, o que nenhum regulador aceita.** O duplo domínio é literalmente o que torna o produto vendável."

2. Target Trial Emulation: o ensaio é o protocolo

> "O TTE consiste em especificar o ensaio ideal e emulá-lo em dados observacionais. **Um SDTM/ADaM de um ensaio real é a especificação mais precisa que existe do target trial** — elegibilidade operacionalizada, time zero definido, desfecho adjudicado. Se eu consigo traduzir isso para OMOP e reimplementá-lo, passo a ter um **alvo validado** contra o qual calibrar a emulação. A maioria das pessoas emula sem nunca ter visto o alvo."

3. Credibilidade regulamentar (DARWIN EU / EMA)

> "Os assessores da EMA leem CDISC. Os dados da rede estão em OMOP. Alguém que consiga mostrar que o estimando é o mesmo nos dois — com uma tabela de concordância e uma listagem de discordâncias com root cause — está a fazer exatamente o trabalho de tradução que um dossiê regulamentar precisa."

4. Reutilização de décadas de dados de ensaios

> "A indústria tem 30 anos de dados em SDTM que não são reutilizáveis entre estudos. Converter para OMOP permite pooling multi-estudo, controlos históricos, e metanálise com código único. O gargalo não é a conversão — é **provar que a conversão preserva o estimando**. Eu construí a prova."

5. Mapeamento de vocabulário bidirecional é mais fácil com o duplo domínio

> "Quem só conhece OMOP mapeia para SNOMED/RxNorm/LOINC. Quem também conhece CDISC sabe que MedDRA e WHODrug são os vocabulários de origem em segurança — e que **MedDRA não é standard no OMOP**, exigindo `CONCEPT_RELATIONSHIP` para navegar. Essa consciência evita perder a granularidade de termos preferidos em segurança."

6. VBHC / ICHOM / PROMs

> "A cadeia de valor completa é: PROM recolhido (Collect) → SDTM em ensaio → OMOP em cuidado rotineiro → outcome comparável. **Perceber os dois extremos da cadeia é o que permite garantir que o outcome medido no ensaio é o mesmo que o medido na vida real.**"

---

5. O DELIVERABLE — O QUE ME CONVENCERIA A CONTRATAR

5.1 ★ O protocolo pré-especificado (o maior diferenciador de todos)

Ninguém em portfolio faz isto. É a diferença entre "alguém que corre queries" e "alguém que desenha estudos."

Escreve um documento de 2–3 páginas por estudo, com esta estrutura (formato adaptado da **tabela de protocolo de target trial** de Hernán & Robins):

Elemento	Especificação
Pergunta causal	"Entre doentes com X, o início de A vs B afeta o risco de Y em 12 meses?"
Estimando	Efeito médio do tratamento na população, ITT vs per-protocol (declara qual)
População elegível	Critérios operacionalizados com códigos e janelas
Estratégias de tratamento	A vs B, com definição de dose/duração
Procedimento de atribuição	Aleatorizado (Proj A) ou new-user com washout (Proj B)
Time zero (baseline)	Data do índice; **elegibilidade definida apenas com informação basal**
Seguimento	Início e fim do TAR, regras de censura
Desfecho	Definição operacional com concept sets
Contraste causal	ITT / per-protocol / as-treated
Análise estatística	Modelo pré-especificado, método de IC, tratamento de missingness
Análises de sensibilidade	Listadas explicitamente (≥3)
Análises de subgrupo	Pré-especificadas e **declaradas como exploratórias**
Potência / precisão	★ Declaração explícita: "com N=50 e 25 por braço, tenho X% de potência para RR=Y; o RR mínimo detetável é Z; **portanto reporto intervalos de confiança e não testes de significância**"

Guidelines a citar (mencionar duas é suficiente e soa muito bem):

- **STROBE** — observacional geral
- **RECORD** — REporting of studies Conducted using Observational Routinely-collected health Data (a mais relevante para RWD)
- **RECORD-PE** — para estudos de farmacoepidemiologia com RWD
- **HARPER** — protocolos de estudos observacionais pré-especificados

5.2 ★ Table 1 com SMD, não com p-values

Este é o detalhe mais revelador de todo o dossiê.

Em ensaios clínicos, a Tabela 1 tem p-values — porque a randomização garante o equilíbrio e o p-value é um teste de que a randomização funcionou (na verdade, logicamente questionável, mas é convenção).

Em RWE, p-values na Tabela 1 estão ativamente errados. Porquê? **O p-value é uma função do tamanho da amostra.** Com N=100.000, diferenças clinicamente triviais tornam-se "significativas". Com N=50, desequilíbrios enormes passam por "não significativos". **Nenhuma das duas situações é informativa.**

O que usar: Standardized Mean Difference (SMD)

```
SMD = (média_expostos − média_não_expostos) / sqrt((s²₁ + s²₂)/2)     [contínuas]
SMD = (p₁ − p₂) / sqrt((p₁(1−p₁) + p₂(1−p₂))/2)                      [binárias]
```

- **|SMD| < 0.10** = bem equilibrado (limiar convencional)
- **|SMD| > 0.10** = desequilíbrio relevante → candidato a ajuste
- **Independe de N** → comparável entre nós da rede (crítico em federação!)

Entregável: um *love plot* — gráfico de SMD pré e pós ajuste (por propensity score), com linha em 0.10.

> **Frase para a entrevista:** "Nunca ponho p-values numa Table 1 de dados observacionais. O p-value mede a minha amostra, não o desequilíbrio. Uso SMD, que é independente de N — e por isso é a única métrica que posso comparar entre nós de uma rede federada com tamanhos muito diferentes."

5.3 Gráficos certos (e errados)

[OK] Correto	[X] Errado
Forest plot com IC 95% e linha de nulidade	Barras com asteriscos de significância
Kaplan-Meier com número-em-risco e IC	KM sem número-em-risco
Love plot de SMD	Tabela de p-values de baseline
Bland-Altman para concordância	Correlação de Pearson para concordância
eDISH plot (log-log, quadrantes Hy's Law)	Gráfico de barras de ALT médio
Spaghetti plot de trajetórias + linha do modelo misto	Boxplot transversal ignorando o tempo
Gráfico de densidade de dados por ano	Nada (ignorar observabilidade)
Gráfico de atrição (barras decrescentes)	Número final sem percurso

5.4 Estrutura do repositório de entregáveis

```
rwe-studies/
├── README.md                        # Mapa dos estudos + como reproduzir
│
├── study-001-trial-replication/     # ★ Estimando ADaM vs OMOP
│   ├── PROTOCOL.md                  # Protocolo pré-especificado
│   ├── 01_cohort_definition.sql
│   ├── 02_teae_replication.py
│   ├── 03_tte_replication.py
│   ├── 04_baseline_replication.py
│   ├── 05_concordance.py            # kappa, ICC, Bland-Altman
│   ├── results/
│   │   ├── concordance_summary.csv
│   │   ├── discordance_listing.csv # ★ com root cause
│   │   └── figures/ (bland_altman, km_comparison)
│   └── STUDY_REPORT.md
│
├── study-002-phenotype-cascade/     # ★ CONCEPT_ANCESTOR
│   ├── PROTOCOL.md
│   ├── conceptSets/*.json           # versionados com sha256
│   ├── 01_build_cohorts.sql
│   ├── 02_phenotype_yield.py        # N por definição + Jaccard
│   ├── 03_sensitivity_estimand.py  # ★ reestima sob cada fenótipo
│   └── results/figures/
│
├── study-003-sccs-drug-safety/      # ★ Self-Controlled Case Series
│   ├── PROTOCOL.md
│   ├── 01_build_sccs_data.py
│   ├── 02_sccs_model.py
│   ├── 03_sensitivity.py            # janela pré-exposição, NCO
│   └── results/figures/
│
└── study-004-database-profile/      # Observabilidade
    ├── 01_achilles_like_profile.py
    └── results/figures/
```

5.5 Notebooks — como os estruturar

Célula 1 (markdown): A pergunta. Uma frase, em linguagem clínica.

Célula 2 (markdown): O protocolo. Tabela PICO-T + estimando + potência declarada.

Célula 3 (código): Concept sets. Carregados de JSON, não inline.

Célula 4 (código): Construção da coorte + TABELA DE ATRIÇÃO. Sempre visível.

Célula 5 (markdown): Interpretação da atrição. Quantos se perderam, e o que isso significa para a generalização.

Célula 6 (código): Table 1 com SMD.

Célula 7 (código): Análise principal + IC.

Célula 8 (código): Análises de sensibilidade.

Célula 9 (markdown): Limitações. ★ Aqui é onde ganhas a entrevista. Escreve:

- Potência real (com os números que calculei em §0.1)
- Precisão dos IC (± 11 pp para proporções em n=58)
- Ameaças à validade nomeadas: viés de observação informativa, prevalent user, viés de deteção, confundimento residual
- **O que mudaria com N = 100.000**

Célula 10 (markdown): "O que este estudo diria se N fosse 100.000." Declara que o código corre inalterado, que a potência passaria a X, e que os **três** aspetos que efetivamente mudariam são: (1) poderias ajustar por mais covariáveis, (2) o viés de publicação/observação tornar-se-ia o problema dominante, (3) precisarias de calibração empírica por NCO.

5.6 O meu ranking pessoal do que mais me impressionaria

Rank	Entregável	Porquê
1	**Protocolo pré-especificado + declaração de potência/precisão**	Ninguém faz. É a prova de que pensas como epidemiologista, não como programador
2	**Estudo de replicação ADaM ↔ OMOP com listagem de discordâncias e root cause**	Usa os teus 3 projetos em simultâneo; é única; é o que uma empresa RWE realmente vende
3	**Tabela de atrição em todas as coortes**	É o idioma nativo da rede federada
4	**Cascata de fenótipos com análise de sensibilidade do estimando**	Demonstra humildade epistémica — a marca do sénior
5	**Table 1 com SMD e love plot**	Detalhe técnico que só quem fez RWE real conhece
6	**SCCS com NCO de diagnóstico**	Topo de gama metodológico; e é o método certo para os teus dados
7	**eDISH plot**	Farmacovigilância regulamentar real; ninguém em portfolio tem
8	**Concept sets versionados em JSON**	Profissionalismo de engenharia aplicado à ciência

6. SCRIPTS PARA PRATICAR EM VOZ ALTA

6.1 Resposta à pergunta "o que farias com estes dados?" (90 segundos)

"Divido os dois projetos por **desenho estatístico**, não por tipo de dados.

O Projeto A tem 50 doentes, 25 por braço, 70 dias. Calculei a potência: tenho 33% para detetar um RR de 2 num risco basal de 20%, e o RR mínimo detetável a 80% de potência é 2.9. **Portanto não vou usar o Projeto A para fazer descoberta — isso seria fabricar evidência.** Vou usá-lo para aquilo em que N=50 é cientificamente suficiente: **replicação**. O ADaM do Projeto C dá-me o valor-verdadeiro de três estimandos — TRTEMFL, tempo até ao primeiro evento adverso, e baseline e mudança desde a baseline. Reimplemento os três em OMOP e meço a concordância doente a doente: kappa para os binários, ICC e Bland-Altman para os contínuos. E o entregável mais importante é a **listagem de discordâncias com root cause**, porque é aí que se vê se eu percebo a semântica ou só a sintaxe.

O Projeto B tem também 58 doentes — mas tem **1.508 pessoas-ano e 16.000 medições**. Aí mudo de registo: em vez de comparar pessoas, comparo **o doente consigo próprio**. Um Self-Controlled Case Series controla automaticamente todos os confundidores invariantes no tempo, e com 50 eventos em tempo exposto deteta um RR de 1.5. Com 26 anos de seguimento e 10 medições por doente-ano, isso é viável.

E em ambos, três coisas que considero inegociáveis: **concept sets versionados** em vez de IDs mágicos inline, **tabela de atrição** em todas as coortes, e **Table 1 com SMD em vez de p-values** — porque o p-value mede a minha amostra, não o desequilíbrio."

6.2 Resposta a "porque é que N=50 não é um problema?" (45 segundos)

"É um problema — para inferência. Não é para demonstração metodológica.

E há uma razão estrutural pela qual N pequeno é até um bom ambiente para isto: numa rede federada, o que viaja entre nós **nunca são os dados, é o código**. O único objeto auditável é a especificação. Portanto a pergunta que interessa não é 'que resultado obtiveste', é 'o teu código produziria o estimando correto se eu o corresse na minha base de 2 milhões?'. E a essa pergunta respondo com N=50 tão bem como com N=2 milhões — desde que reporte **precisão em vez de**

significância.

Com N=50, qualquer erro de especificação é visível. Com 2 milhões, um erro de especificação produz uma estimativa estreita e errada, e ninguém o deteta. **A amostra pequena é onde se apanham os erros de desenho.**"

6.3 Resposta a "como usas o CONCEPT_ANCESTOR?" (40 segundos)

"Para fenotipagem hierárquica, e com quatro cuidados.

Primeiro: expando a partir do conceito de interesse com `ancestor_concept_id = X`, e uso `min_levels_of_separation` para controlar granularidade.

Segundo: `SELECT DISTINCT` **é obrigatório** — um conceito pode ter múltiplos caminhos até ao mesmo ancestor, e sem DISTINCT duplico registos e inflaciono o numerador silenciosamente.

Terceiro: nunca salto vocabulário — a hierarquia é intra-vocabulário.

Quarto, e o mais importante: **não uso um único fenótipo, uso uma cascata.** Quatro definições aninhadas — código único, dois códigos em datas distintas, mais terapêutica, mais valor laboratorial — e depois **reestimo o desfecho primário sob cada uma**. A pergunta não é qual é o fenótipo certo; é quão sensível é a minha estimativa a essa escolha. Se o RR passa de 1.8 para 1.1 conforme endureço a definição, esse resultado não é robusto, e é essa informação que eu entrego."

6.4 Resposta a "qual é a tua maior limitação?" (30 segundos)

"Além do N: **não tenho MedDRA no meu vocabulário standard.** Em segurança de ensaios clínicos, a granularidade regulamentar vem de Preferred Terms MedDRA, e o OMOP não os tem como standard por defeito — tenho de navegar via `CONCEPT_RELATIONSHIP` ou agrupar por ancestors SNOMED. Isso significa que a minha agregação por órgão e sistema no Projeto A é uma aproximação, e eu declaro-a como tal em vez de a apresentar como equivalente a um SOC MedDRA.

E no Projeto B não tenho validação clínica dos fenótipos — tenho rendimento e sobreposição, não sensibilidade e especificidade contra um gold standard. Sem isso, o que tenho é uma análise de sensibilidade honesta, não um fenótipo validado."

---

7. PLANO DE EXECUÇÃO PRIORIZADO

Se tiveres 2 semanas antes da entrevista:

Dia	Tarefa	Tempo
1	**Eliminar os 3 anti-padrões** (`320128`, `ILIKE '%covid%'`, `LIKE '%acetaminophen%'`) e substituir por concept sets JSON + `CONCEPT_ANCESTOR`	3h
2	**Estudo B1: cascata de fenótipos** com tabela de atrição e análise de sensibilidade do estimando	6h
3	**Perfil de observabilidade** (densidade por domínio por ano, % concept_id=0)	3h
4–5	**Estudo A1: replicação TRTEMFL + TTE** com κ, Bland-Altman, listagem de discordâncias	10h
6	**PROTOCOL.md** para cada estudo, com declaração de potência/precisão	4h
7	**Table 1 com SMD + love plot**	4h
8	**eDISH plot** (se o LB tiver `range_high`)	3h
9–10	**SCCS** com análise de sensibilidade (janela pré-exposição)	10h
11	Notebooks narrativos + figuras	6h
12	**Verificar se Achilles corre sobre o teu DuckDB** via `DatabaseConnector(dbms="duckdb")`	3h

Dia	Tarefa	Tempo
13	Testes de contrato + README	3h
14	Preparar os 4 scripts de §6 em voz alta	2h

Se só tiveres 3 dias: faz **dia 1** (anti-padrões — é o de maior rendimento por hora), **dia 2** (cascata de fenótipos + atrição), **dia 6** (protocolos com potência). Esses três sozinhos mudam a perceção que um Lead Epidemiologista tem de ti.

RESUMO EM UMA FRASE

> **Deixa de vender pipelines e passa a vender estimandos. O teu pipeline já é bom; o que falta provar é que sabes que pergunta lhe fazer — e que sabes quando os teus dados não têm potência para responder.**