RWE — Estratégia Analítica e de Dados

Estudos, métricas, estratégia de dados e apresentação | Outubro 2026

Estratégia Analítica, Estatística e de Dados

RWE · Ensaio Clínico · OMOP CDM · Posicionamento de Mercado

Perspetiva: Senior Health Data Scientist / Lead Epidemiologist
Ponto de partida: três pipelines funcionais (raw→CDISC, CDISC→OMOP, FHIR→OMOP) e duas bases OMOP operacionais em DuckDB
Data: outubro de 2026

> Este documento é o **plano diretor**. O detalhe metodológico estudo-a-estudo dos Projetos A e B está em `RWE_ANALYTICS_DOSSIER.md`; aqui não o repito — assumo-o como base e construo por cima: estado da arte, portefólio de estudos nos **três** projetos, estratégia de dados, e arquitetura de apresentação.

---

0. SUMÁRIO EXECUTIVO — a tese em nove parágrafos

1. Tens um ativo que quase ninguém tem, e não é o que pensas. Não são "três pipelines". É uma **ponte bidirecional CDISC ↔ OMOP com camada de vocabulário governada**. A maior parte das pessoas no mercado sabe fazer ETL para OMOP. Uma minoria sabe fazer SDTM/ADaM. Quase ninguém faz os dois e consegue medir a concordância entre eles. Isso é a tua vantagem real, e é o eixo à volta do qual a camada analítica deve ser construída.

2. A camada analítica não é "mais código". É uma mudança de unidade de entrega. Um pipeline entrega tabelas. Uma análise entrega **uma afirmação com um intervalo de confiança e uma lista de razões pelas quais essa afirmação pode estar errada**. Tudo o que construíres daqui para a frente tem de produzir o segundo objeto, não o primeiro.

3. O mercado mudou a teu favor em 2025–2026, e de forma datável. A FDA publicou a orientação final de RWE a 18 de dezembro de 2025 e, dez dias antes, anunciou que aceita RWE sem exigir dados individuais identificáveis. A União Europeia publicou o primeiro relatório de Avaliação Clínica Conjunta (JCA) a 9 de junho de 2026. O EHDS torna o acesso secundário operacional a 26 de março de 2029. Nada disto é abstrato: são **prazos que estão a criar procura por pessoas que saibam executar estudos sobre modelos comuns**.

4. A pergunta "sintético ou MIMIC?" está mal formulada. A pergunta correta é: **que afirmações é que cada tipo de dado te licencia a fazer?** Dados sintéticos licenciam afirmações metodológicas ("o meu estimador recupera o efeito verdadeiro"). Dados reais credenciados licenciam afirmações clínicas ("este fármaco associa-se a este risco"). Confundir as duas é o erro que destrói candidaturas em 30 segundos de entrevista.

5. A resposta operacional é: os dois, em papéis diferentes — e há um movimento de alavancagem altíssima que podes fazer este fim de semana. O MIMIC-IV Clinical Database Demo existe em três formas independentes do **mesmo** conjunto de 100 doentes: relacional nativo, **FHIR R4** e **OMOP**. Isso permite-te fazer algo que praticamente ninguém faz: comparar a tua conversão FHIR→OMOP contra a conversão de referência do OHDSI, doente a doente, conceito a conceito. Custo zero. Sem credenciais. Chamo a isto **validação diferencial**, e é o estudo mais valioso do teu portefólio.

6. Sobre "passar dados externos pelo meu ETL ou usar pré-mapeado": há uma regra de decisão. Se **o ETL é a afirmação**, passa-o pelo teu pipeline. Se **a análise é a afirmação**, usa o pré-mapeado. Nunca faças engenharia de semanas sobre um dataset que já tem conversão oficial, para no fim correr uma regressão logística. E mesmo quando usares pré-mapeado, corre DQD sobre ele — as conversões publicadas têm lacunas documentadas, e quantificá-las já é um diferenciador.

7. Os teus dados atuais não sustentam inferência comparativa, e isso não é um problema — é o teu enquadramento. 25 doentes por braço dá 33% de potência para um RR de 2.0. Mas 1.508

pessoas-ano e 16.000 medições sustentam desenhos intra-pessoa. E, acima de tudo, sustentam **estudos de métodos com verdade conhecida**, que é onde a credibilidade se ganha sem precisar de escala.

8. A apresentação é o produto. O que separa "candidato com projetos" de "candidato contratável" não é a quantidade de análises — é ter **quatro pacotes de estudo com protocolo, atrição, diagnósticos, sensibilidade e manifesto de reprodutibilidade**. Quatro pacotes excelentes valem infinitamente mais do que vinte notebooks.

9. A minha recomendação em uma frase: constrói **quatro estudos-bandeira**, cada um a provar um músculo diferente — engenharia (validação diferencial), estatística regulatória (estimand lab), epidemiologia (o custo do RWD), e maturidade em dados reais (informed presence) — e entrega cada um como um pacote auditável, não como um resultado.

PARTE I — ESTADO DA ARTE, OUTUBRO 2026

1.1 O enquadramento regulatório que criou este mercado

Isto não é contexto decorativo. É a razão pela qual alguém te paga.

Data	Acontecimento	Consequência prática para ti
15 dez 2025	FDA anuncia que aceita RWE sem exigir sempre dados individuais identificáveis em submissões de dispositivos	Abre a porta a evidência gerada em ambientes federados e des-identificados — exatamente o modelo OMOP
18 dez 2025	FDA publica a orientação final Use of Real-World Evidence to Support Regulatory Decision-Making for Medical Devices, substituindo a de 2017	Define "relevance" e "reliability" como os dois eixos de avaliação. Implementação a partir de **17 fev 2026**
jan 2025 →	Regulamento (UE) 2021/2282 (HTA) aplica-se. JCA obrigatória para novos princípios ativos em oncologia e ATMP. Evidência submetida em **100 dias** após notificação	Cria pressão brutal por **execução rápida e pré-especificada** — o oposto de análises exploratórias
30 abr / 9 jun 2026	Primeira JCA aprovada (tovorafenibe, glioma pediátrico de baixo grau) e primeiro relatório publicado	O mecanismo deixou de ser teórico. Em 2026 estão previstas ~35 JCA oncológicas, ~15 ATMP e ~5 de dispositivos
26 mar 2027	EHDS: aplicação geral	Governação e implementing acts
26 mar 2029	EHDS Capítulo IV: **uso secundário operacional**; HDABs emitem licenças de dados; HealthData@EU ativo	Mercado europeu de acesso secundário a dados de saúde passa a existir formalmente
26 mar 2031	Uso secundário estende-se a dados genómicos e **dados de ensaios clínicos**	A ponte CDISC↔OMOP que construíste torna-se infraestrutura, não curiosidade

O que isto significa. O EHDS é permit-based, não consent-based: acesso através de licença, com análise dentro de ambientes seguros. Isto é, por desenho, **um modelo federado com processamento local**. É literalmente a arquitetura do OMOP. Quem em 2029 tiver competência em executar estudos sobre CDM num nó local, com protocolo auditável, estará do lado certo de um mercado criado por regulamento.

E o número que deves saber de cor. No quarto relatório do EMA sobre RWE (período 8 fev 2025 – 7 fev 2026), a DARWIN EU registou: **108 tópicos avaliados, 88 estudos concluídos ou em curso (+49% face ao período anterior), 43 concluídos, taxa de viabilidade ~78–80%, e uma mediana de 4,8 meses (IQR 4–6) entre aprovação do protocolo e resultados**. A mediana de parceiros de dados por estudo subiu de **3 para 6**. E o OHDSI, em colaboração com o Uppsala Monitoring Centre, desenhou e executou um estudo completo com `Strategus` sobre registos nacionais suecos **em cinco dias**.

Lê isto duas vezes: um estudo regulatório, federado, multi-nó, em 4,8 meses é o benchmark de mercado. Se o teu pacote de estudo não conseguir ser entregue num nó novo em dias, não está ao nível.

1.2 O enquadramento metodológico — o que é hoje padrão e o que é hoje diferenciador

Já é padrão (não te distingue, mas a ausência desqualifica):

- Desenho new-user, active-comparator; nunca prevalent-user passivo
- Propensity score de larga escala com large-scale regularised regression, avaliação por **SMD** e não por p-values
- Target Trial Emulation com time zero alinhado entre elegibilidade, tratamento e seguimento
- Negative control outcomes e **calibração empírica** de p-values e intervalos de confiança
- Reporte segundo STROBE / RECORD / RECORD-PE; avaliação de risco de viés por ROBINS-I
- **Estimand** com os cinco atributos de ICH E9(R1)

Ainda é diferenciador (aqui é que ganhas):

- **Quantificação de informed presence / informative observation** — a literatura de 2025–2026 está a mostrar que é uma fonte de confundimento sub-reconhecida, e quase ninguém a trata operacionalmente num pipeline
- **Ligar falhas de DQD ao impacto no estimando** — passar de "o DQD passou" para "esta falha enviesa este estimando nesta direção e nesta magnitude"
- **Análise de *fitness for purpose*** da fonte, não só de qualidade genérica
- **Calibração por simulação plasmode** com verdade conhecida — provar que o estimador recupera o parâmetro, com cobertura de IC ≈ 95%
- **Documentar o custo do RWD**: quanto do efeito se perde quando passas de um ensaio para dados observacionais
- **Reprodutibilidade ligada ao vocabulário** (assinatura criptográfica do conjunto de vocabulários, não apenas "v5.0")
- **Duplo domínio CDISC/ADaM ↔ OMOP** — raríssimo e diretamente monetizável

Um detalhe que separa seniores de juniores, e que vais usar como sinal: a razão de proporções de notificação (PRR) e o reporting odds ratio (ROR) são medidas de **desproporcionalidade em notificação espontânea** (farmacovigilância tipo VigiBase/EudraVigilance). **Não são válidas em dados de EHR em coorte**, porque não há denominador de exposição e o reporting é enviesado por notoriedade. Num EHR calculas **taxa de incidência**, não desproporcionalidade. Dizer isto espontaneamente numa entrevista sinaliza formação real.

1.3 O enquadramento técnico — a stack que deves dominar e a que deves saber nomear

Camada	Ferramenta	Nota
Orquestração de estudo	`Strategus` (spec JSON → módulos)	É o padrão de facto para estudos de rede. Versão 1.5.x. Um spec JSON é hoje o formato em que um estudo viaja entre nós
Estimação causal	`CohortMethod` (v6.x, no CRAN desde mar 2026), `SelfControlledCaseSeries`, `CohortIncidence`, `Characterization`	Pacotes HADES
Síntese federada	`EvidenceSynthesis`	Meta-análise sem partilha de dados individuais; intervalos de previsão
Diagnóstico de fenótipos	`CohortDiagnostics`, `PhenotypeR`, `PheValuator`	
Qualidade	`DataQualityDashboard` (já o usas), **Achilles**	
Ligação a CDM	`CDMConnector` + `omopgenerics` (R), `SqlRender`/`DatabaseConnector`	`CDMConnector` fala DuckDB nativamente
Programação estatística regulatória	**pharmaverse**: `admiral`, `sdtmchecks`, `xportr`, `metacore`/`metatools`, `rtables`, `cards`, `chevron`, `tfrmt`	O equivalente moderno do SAS

Camada	Ferramenta	Nota
Validação CDISC	**CDISC CORE** (motor de regras open-source), Pinnacle 21, `sdtmchecks`	
Motor local	**DuckDB**	A tua escolha está validada: há pipelines `dbt`+DuckDB para MIMIC-IV→OMOP publicados em 2026, a correr em hardware de consumidor

Ponto de honestidade sobre DuckDB. O `Strategus` e a generalidade do HADES assumem R + JDBC. Não vais correr `CohortMethod` em DuckDB. A arquitetura correta é: **DuckDB para ETL, qualidade e exploração; R/PostgreSQL para a camada de estimação HADES**. Saber dizer isto — e saber que `DatabaseConnector` tem suporte DuckDB mas que o ecossistema de resultados assume PostgreSQL — é exatamente o tipo de detalhe que um Data Lead testa.

1.4 A janela

Três factos que, juntos, definem a tua janela de oportunidade:

- **A regulamentação criou procura** (FDA 2025, JCA 2026, EHDS 2029) por execução de estudos sobre modelos comuns.
- **A tooling tornou-se acessível** (DuckDB, HADES, pharmaverse, MIMIC aberto) — deixou de ser preciso um departamento de TI.
- **A competência escassa não é a tooling** — é julgar. É saber quando um efeito é real, quando é informed presence, quando é confundimento por indicação, e quando é simplesmente ruído numa amostra de 58.

A camada analítica que vais construir tem de demonstrar o ponto 3. Os pontos 1 e 2 são o vento de cauda.

PARTE II — Q1: OS ESTUDOS, POR PROJETO

2.0 Como priorizei

Critério: **valor demonstrativo ÷ esforço**, com um ajuste — cada estudo tem de provar um músculo **diferente**. Repetir o mesmo músculo quatro vezes não soma.

Músculo	Estudo que o prova	Porque é insubstituível
Engenharia medida	X1 — Validação diferencial	Prova que sabes medir a correção de uma conversão, não só fazê-la
Estatística regulatória	P1.1 — Estimand Lab	Prova que pensas em termos de E9(R1) e não de "p-value"
Epidemiologia	P2.4 — O Custo do RWD	Prova que entendes porque a evidência observacional é difícil
Maturidade em dados reais	P3.3 — Informed presence	Prova que não confundes dados com medições

Os outros estudos são suporte: alguns são necessários, nenhum é diferenciador por si.

2.1 Projeto 1 — Raw → CDISC (SDTM/ADaM): a camada analítica é statistical programming

Primeiro, a distinção que quase todos falham. Num ensaio, **o ADaM é a camada analítica**. Não há "uma camada de análise por cima do ADaM" — o ADSL é a Tabela 1, o ADAE é a análise de segurança, o ADTTE é a sobrevivência. Portanto, para o Projeto 1, "desenvolver a camada analítica" significa **subir ao nível de qualidade regulatório**, não acrescentar gráficos.

E há aqui um ativo que provavelmente não estás a usar: o CDISC Pilot 01 é público.

O estudo `CDISCPILOT01` — xanomelina em adesivo transdérmico, fase III, doença de Alzheimer ligeira a moderada — está integralmente disponível em `github.com/cdisc-org/sdtm-adam-pilot-project`, com **306 doentes rastreados, 254 aleatorizados (86 placebo, 84 dose baixa, 84 dose alta)**, endpoint primário ADAS-Cog(11) variação desde baseline à semana 24, e — crucialmente — **SDTM e ADaM completos, com `define.xml` para ambas as camadas**. Os ADaM incluem `adsl` (254 linhas), `adae`, `adlbc` (74.264), `adlbh` (49.932), `advs`, `adtte`, `adqsadas`, `adqscibc`, `adqsnpix`.

Ou seja: tens um **gabarito oficial** contra o qual validar o teu pipeline raw→SDTM→ADaM. Isso transforma o Projeto 1 de "construí um pipeline" em "construí um pipeline cujos outputs batem certo com uma submissão de referência". É a diferença entre confiança e evidência.

P1.1 — ★ ESTIMAND LAB: os mesmos dados, três estimandos, três respostas

O estudo-bandeira do Projeto 1. E é simples de executar, devastador de apresentar.

A pergunta: o ensaio tem descontinuações por eventos adversos no domínio `DS`. Um doente que sai aos 3 meses por intolerância — o que fazes com ele na análise? A resposta **muda o resultado**, e a maior parte das pessoas não sabe que muda.

Desenho. Sobre o `CDISCPILOT01`, define o evento intercorrente "descontinuação do tratamento por evento adverso" (a partir de `DS`, `DSDECOD`, e `AE` com `AEACN = 'DRUG WITHDRAWN'`). Implementa três estratégias de ICH E9(R1):

Estratégia	Definição operacional	População de análise	O que mede
Treatment policy	Ignora a descontinuação; usa todos os dados pós-randomização independentemente da adesão	Todos os aleatorizados	Efeito de atribuir o tratamento
Hypothetical	Censura o doente na descontinuação (ou usa copy reference / múltipla imputação)	Todos os aleatorizados	Efeito se todos tolerassem
Composite	Descontinuação por EA conta como falha do desfecho	Todos os aleatorizados	Efeito sobre "sucesso sem intolerância"

E adiciona uma quarta, a que os reguladores mais gostam de discutir: **while-on-treatment**.

O entregável não é o número — é a tabela. Uma linha por estratégia: estimativa, IC 95%, e uma frase a explicar porque é diferente. Quando as três divergirem (e vão divergir, porque a descontinuação por EA está associada ao braço ativo), tens a demonstração mais limpa que existe de que o estimando é uma **decisão de desenho**, não uma propriedade dos dados.

Como o apresentas em entrevista, em 20 segundos:

> "Peguei no CDISC Pilot público e implementei o mesmo endpoint sob quatro estratégias de evento intercorrente. O efeito no braço alto muda de X para Y conforme a estratégia. Não é um bug — é a razão pela qual o E9(R1) existe. Se o protocolo não declara o estimando, o resultado é negociável depois de o veres, e isso é precisamente o que a FDA e a JCA estão a tentar eliminar."

Isto é muito difícil de responder em cima. É a tua melhor carta no Projeto 1.

P1.2 — Double programming com relatório de comparação

Re-deriva um subconjunto de ADaM (`ADSL`, `ADAE`, `ADTTE`) **duas vezes, independentemente** — uma em R (`admiral`, `metacore`) e outra em SQL/DuckDB ou SAS — e produz um **relatório de comparação programático**: contagem de linhas, igualdade variável a variável, tolerância numérica, e lista de divergências com causa-raiz.

Porque vale a pena: double programming é o ritual de qualidade da indústria farmacêutica. A maior parte dos candidatos diz "sei SAS e R". Praticamente nenhum traz um comparison report real. E faz uma coisa subtil: prova que percebes que a independência da segunda implementação é o que dá valor — se ambas usarem a mesma função, não é dupla programação, é a mesma programação duas vezes.

P1.3 — Reconstrução de TLF a partir do ADaM

Tabela 1 (demografia, baseline, história de doença), tabela de exposição, `ADAE` por SOC/PT com treatment-emergent flag, `ADTTE` com Kaplan-Meier e HR de Cox, e shift tables de laboratório (baseline → pior valor pós-baseline). Com `rtables`/`chevron` ou `gtsummary`.

Nota de priorização: este é o estudo que eu **cortaria primeiro** se o objetivo for uma empresa de RWE e não uma CRO. É competência valiosa, mas pertence a outro mercado. Mantém-no **como apêndice** do pacote P1.1, não como estudo autónomo.

P1.4 — Validação formal e `define.xml`

Corre `sdtmchecks` e/ou **CDISC CORE** sobre os teus datasets, produz o relatório de conformidade, e — se tiveres energia — gera `define.xml` 2.1 com `metacore`/`xportr`. Para dados OMOP, corre o teu DQD.

Porque vale a pena: em 30 segundos mostras que conheces o lado conformance do ciclo regulatório, não só o lado analysis.

P1.5 — Re-derivação de potência: o que o protocolo assumiu vs o que os dados entregaram

Recalcula, a partir do `ADSL`/`ADAS-Cog`, o desvio-padrão observado, o efeito assumido no protocolo e a potência que o estudo **realmente** tinha. Compara com o desvio-padrão usado no cálculo original.

Porque vale a pena: é um exercício de humildade estatística que quase ninguém faz, e liga diretamente ao problema dos teus próprios N=50/58. Mostra que pensas em potência antes de pensar em resultados.

P1.6 — A ponte: SDTM → OMOP → estimando, e de volta

Já está no `RWE_ANALYTICS_DOSSIER.md` (§4) como estudo de reconciliação. Aqui acrescento só o enquadramento estratégico: **este é o estudo que liga os teus três projetos num só argumento**. Se conseguires mostrar que o mesmo estimando, calculado (a) sobre ADaM e (b) sobre OMOP derivado do mesmo SDTM, converge dentro de tolerância pré-definida, então provaste que a tua conversão preserva a **semântica analítica** — não apenas o formato. Isso é uma afirmação muito mais forte do que "os row counts batem certo".

2.2 Projeto 2 — CDISC → OMOP: para além dos estudos clínicos

Os estudos A1–A6 (replicação, farmacovigilância com eDISH/Hy's Law, sobrevivência, trajetórias laboratoriais, medicação de resgate, mecânica de new-user) estão detalhados no dossiê anterior. Aqui acrescento os dois que faltavam, e que são melhores do que qualquer um deles.

P2.4 — ★ O CUSTO DO RWD: a escada de degradação

Este é o estudo mais inteligente que podes fazer com o Projeto 2. E é praticamente inédito como peça de portefólio.

A ideia. Tens um ensaio aleatorizado com uma verdade conhecida (o efeito do braço ativo vs placebo, já medido em A1). Agora **degrada-o progressivamente até parecer dados observacionais reais**, um degrau de cada vez, medindo em cada degrau quanto é que a estimativa se afasta da verdade.

Degrau	O que removes	Viés que introduzes	Como o corriges
D0	Nada — ensaio íntegro	Nenhum (referência)	—
D1	A aleatorização (atribuição por indicação)	**Confundimento por indicação**	Propensity score, IPTW
D2	A regularidade das visitas (só se mede quando há contacto)	**Informed presence** / informative observation	Inverse intensity weighting

Degrau	O que removes	Viés que introduzes	Como o corriges
D3	O seguimento completo (censura associada ao desfecho)	**Censura informativa**	IPCW, clone-censor-weight
D4	A classificação perfeita do desfecho (códigos em vez de adjudicação)	**Misclassificação não-diferencial**	Análise de sensibilidade quantitativa (matriz de confusão)
D5	A adesão registada (doses omitidas não observadas)	**Adesão imperfeita / as-treated enviesado**	New-user + PDC, treatment policy
D6	Tudo em simultâneo — "isto agora é um EHR"	Todos os anteriores, interagindo	Pacote completo

O que produzes: um gráfico de forest plot onde cada degrau é uma linha, com a estimativa, o IC, e **a verdade do ensaio como linha vertical de referência**. Vês a estimativa a deslizar. E vês quanto de cada deslize é recuperado pela correção apropriada.

Porque é que isto é ouro:

- Prova, com números teus, que entendes **porque** a evidência observacional é difícil — não como frase feita, mas como uma curva.
- Dá-te uma resposta devastadora a "qual é a limitação da tua análise?" — não uma limitação, um orçamento de viés quantificado.
- É o argumento comercial de qualquer empresa de RWE, demonstrado em vez de afirmado: "a diferença entre um ensaio e o mundo real tem este tamanho, e a nossa tecnologia recupera esta fração dela."
- Não exige dados externos. Só exige que sejas honesto com os teus.

O rigor que o torna publicável: define a métrica de erro **antes** de correr (viés absoluto em escala log, e cobertura do IC 95%), e repete o processo em pelo menos 200 réplicas por degrau com sementes registadas. Sem repetição, estás a mostrar uma trajetória; com repetição, estás a mostrar uma distribuição.

P2.7 — Viabilidade de braço de controlo sintético (arquitetura, não afirmação)

Com 25 doentes por braço, **não podes** produzir um braço de controlo sintético credível, e deves dizê-lo antes que te perguntem. O que **podes** fazer é entregar a **arquitetura** e a **análise de requisitos**: quantos doentes externos seriam necessários para igualar a precisão do braço aleatorizado, que covariáveis teriam de estar disponíveis em ambos os lados, que método de ponderação (IPTW, entropy balancing, matching with caliper) e que diagnóstico de comparabilidade.

Porque vale a pena: os synthetic control arms são um dos temas comerciais mais quentes (e mais contestados) em RWE. Demonstrar que sabes calcular o **requisito de tamanho e de comparabilidade** — em vez de fingir que o resolves com 25 doentes — é sinal de senioridade, não de fraqueza.

2.3 Projeto 3 — FHIR → OMOP: onde a janela de 26 anos se transforma em método

Os estudos B1–B8 estão no dossiê. Os dois novos são os melhores que este projeto permite.

P3.3 — ★ INFORMED PRESENCE: quantificar o viés que os teus dados têm por construção

Este é o estudo que prova maturidade em dados reais. E é o que a literatura de 2025–2026 está a pedir e quase ninguém implementa.

O problema. Num EHR, um doente não "tem" 276 medições. Ele tem 276 medições **porque foi ao hospital 276 vezes**. A frequência de contacto é determinada pela saúde do doente, pelo acesso, pela prática clínica e pelo diagnóstico. Logo, o ato de medir está correlacionado com o desfecho. Isto não é missing data no sentido clássico: é **presença informativa** — os dados que existem não são uma

amostra aleatória dos dados que existiriam se todos fossem medidos.

A evidência de que isto não é teoria. Num estudo de 2026 sobre dados de EHR longitudinais, uma razão de taxas de incidência que era **1,83 (IC 95% 1,02–3,28)** numa análise ingénua passou a **1,37 (0,73–2,57)** depois de contabilizada a informed presence por inverse intensity weighting. O efeito não desapareceu — **atenuou-se**, e o intervalo passou a incluir o nulo. Em sentido oposto, outro trabalho de 2026 encontrou que **o número de vezes que um peso é registado** era o preditor mais forte de 10 desfechos cardiovasculares — mais forte do que o peso mínimo, máximo, médio, a variação ou o IMC. A frequência de medição é, ela própria, um confundidor.

O desenho, nos teus dados.

- **Caracteriza o processo de visita.** Modela a intensidade de contacto (visitas por pessoa-ano) em função de idade, sexo, comorbilidade (Charlson), e número de condições ativas. Produz o perfil de quem é "observado com frequência".
- **Mostra que a intensidade prediz o desfecho.** Regressão de Poisson ou Cox com a intensidade de visita como exposição. Se prediz — e vai predizer — tens confundimento por informação, não por doença.
- **Repete uma associação concreta, ingénua vs corrigida.** Escolhe uma associação plausível nos teus dados (biomarcador → desfecho, ou fármaco → desfecho). Estima (a) em todos os registos, (b) só em contacto de rotina/ambulatório, (c) com inverse intensity weighting por visita, (d) com multiple outputation como verificação. Reporta as quatro.
- **Quantifica o *reporting rate ratio*** e a diferença entre estimativas.
- **Faz a análise de sensibilidade quantitativa** para o caso de a intensidade estar ela própria afetada por exposição e desfecho (aí condicionar introduz **viés de colisor** — e tens de o dizer).

Porque é que isto te distingue. A maior parte das pessoas que "usa EHR" trata o número de medições como um dado. Tu tratas como um **processo gerador de dados** que tem de ser modelado. É a diferença entre usar dados e fazer inferência a partir de dados. E é exatamente o tipo de raciocínio que um Lead Epidemiologist procura — porque é a razão pela qual a maior parte dos estudos de RWE falha em revisão.

Uma nota de rigor: em 100 ou 58 doentes, o modelo de intensidade vai ser instável. Reporta-o como **estimativa de viabilidade com intervalos largos**, não como resultado definitivo. O entregável é a **demonstração de que sabes executar e corrigir o procedimento**, com o efeito estimado como subproduto.

P3.9 — DQD → fitness for purpose: ligar qualidade de dados a viés

Já sabes correr DQD e já tens política de qualidade (`quality/dqd_policy.json`, `max_errors: 0`, `max_failed_checks: 0`). O passo que quase ninguém dá é o seguinte:

Para cada check falhado, escreve a consequência analítica. Três exemplos concretos do teu domínio:

Falha DQD	Consequência no estimando
`measurement_unit_concept_id` nulo numa fração dos registos	Valores não comparáveis entre doentes → erro de medição não-diferencial → atenuação do HR em direção ao nulo
`condition_start_date` anterior a `birth_datetime`	Eventos impossíveis → se correlacionados com o centro, confundimento por centro
`drug_exposure_end_date` nulo / `days_supply` ausente	Impossível calcular PDC/MPR → persistência não estimável, ou estimada só na subcoorte com dados completos (que não é aleatória)

Isto transforma o DQD de um checkbox de engenharia num **instrumento de avaliação de risco de viés**. É a diferença entre "o meu pipeline é limpo" e "o meu pipeline é limpo no sentido que importa para esta pergunta".

E há um segundo uso, mais fino: **correr o DQD sobre o MIMIC-CDM de referência**. As conversões publicadas têm lacunas documentadas — o demo OMOP do OHDSI/MIMIC, por exemplo, não incorpora

`inputevents`/`outputevents` e não preenche notas. **Quantificar a qualidade de um dataset de referência** é uma coisa que quase nenhum utilizador de MIMIC faz, e que demonstra que não tratas dados publicados como verdade revelada.

P3.10 — Predição: porque é que eu a adiava

Com 58 doentes e 16.000 medições, tens ~276 medições por doente. Qualquer modelo preditivo ao nível do doente vai ter um AUROC com intervalo de confiança gigante, e vai falhar os requisitos mínimos de tamanho de amostra de Riley et al. para desenvolvimento de modelos. Um revisor experiente vê isso em 10 segundos, e o efeito é **negativo** — não é "não provou", é "não sabe que não pode".

Se quiseres a camada preditiva, a resposta é MIMIC-IV completo (credenciado, >300 mil doentes), com `PatientLevelPrediction`, validação interna por bootstrap, reporte TRIPOD+AI, e avaliação PROBAST+AI. Aí a predição é defensável. Antes disso, é teatro.

2.4 A tabela mestra

ID	Estudo	Dados	Método central	Prova	Esforço	Valor
X1	★ Validação diferencial da conversão	MIMIC-IV Demo (relacional + FHIR + OMOP)	Concordância de conceitos, κ, DQD lado a lado	Engenharia	M	**Máximo**
P1.1	★ Estimand Lab	CDISCPILOT01 (público)	ICH E9(R1), 4 estratégias de evento intercorrente	Estatística reg.	S	**Máximo**
P2.4	★ O Custo do RWD	Projeto A (próprio)	Escada D0–D6, 200 réplicas, viés e cobertura	Epidemiologia	M	**Máximo**
P3.3	★ Informed presence	Projeto B (próprio)	Inverse intensity weighting, QBA	Dados reais	M	**Máximo**
P1.2	Double programming	CDISCPILOT01	R vs SAS/SQL + comparison report	Rigor	M	Alto
P1.3	TLF a partir de ADaM	CDISCPILOT01	`rtables`/`chevron`, KM, shift tables	Rigor	M	Médio
P1.4	Conformidade CDISC	Projeto 1	`sdtmchecks`/CORE, `define.xml`	Conformidade	S	Médio
P1.5	Re-derivação de potência	CDISCPILOT01	Potência observada vs assumida	Humildade	S	Médio
P1.6	Ponte ADaM↔OMOP	Projetos 1+2	Replicação de estimando, κ/ICC	**Duplo domínio**	M	**Máximo**
P2.1	Replicação/reconciliação	Projeto A	ADaM vs OMOP, Bland-Altman	Rigor	S	Alto
P2.2	Farmacovigilância + eDISH	Projeto A	IR exata, Hy's Law	Clínico	S	Alto
P2.3	Sobrevivência + TTE	Projeto A	KM, Cox, RMST	Clínico	S	Alto
P2.5	Medicação de resgate	Projeto A	Treatment patterns	Clínico	S	Médio
P2.7	Viabilidade de SCA	Projeto A	Requisitos de precisão e comparabilidade	Arquitetura	S	Alto
P3.1	Cascata de fenótipos	Projeto B	`CONCEPT_ANCESTOR`, concept sets	OHDSI	S	Alto
P3.2	Perfil de observabilidade	Projeto B	Achilles, caracterização	Qualidade	S	Alto
P3.4	Persistência e adesão	Projeto B	PDC/MPR, Kaplan-Meier de descontinuação	Clínico	S	Alto
P3.5	Trajetórias de biomarcadores	Projeto B	Modelos mistos, decomposição within/between	Estatística	S	Alto

ID	Estudo	Dados	Método central	Prova	Esforço	Valor
P3.6	SCCS	Projeto B	SCCS com intervalos dependentes do evento	Farmacoepi	M	Alto
P3.7	Multimorbilidade	Projeto B	Charlson/Elixhauser, SMD	Descritivo	S	Médio
P3.8	Controlos negativos + calibração	Projeto B	`EmpiricalCalibration`	Rigor	M	Alto
P3.9	DQD → viés	Projeto B	Mapeamento falha→consequência	Qualidade	S	Alto
X2	Rede federada num portátil	Projeto B fragmentado	Sharding + spec + `EvidenceSynthesis`	Federado	M	Alto
X3	Simulação plasmode	Projeto B / MIMIC	Verdade conhecida, cobertura de IC	Métodos	M	**Máximo**

Regra de execução: quatro estudos-bandeira, mais os de esforço **S** que consigas fechar em fins de semana. Nada de começar dez.

PARTE III — Q2: PERGUNTAS CLÍNICAS, MÉTRICAS E METODOLOGIAS

3.1 A escada de ambição — sobe um degrau de cada vez

Degrau	Pergunta	Métrica	Nunca dizes
1. Descrição	Quem está na base de dados?	Contagens, mediana (IQR), cobertura	"significativo"
2. Caracterização	Como se distribuem exposições e desfechos?	Prevalência, incidência por 1.000 pessoas-ano	"associação"
3. Comparação ajustada	Há diferença entre grupos?	HR/OR/IRR com IC 95%, SMD	"causa"
4. Causal	Qual seria o efeito se interviéssemos?	Estimando + IPTW/PS + análise de sensibilidade	"provámos"
5. Predição	Quem vai ter o desfecho?	AUROC **+ calibração** + Brier + DCA	"diagnostica"
6. Decisão	Vale a pena tratar?	NNT, custo-efetividade, análise de decisão	—

A maior parte dos portefólios vive no degrau 2 e chama-lhe degrau 4. O teu valor está em **explicitar em que degrau cada estudo está**.

3.2 Perguntas clínicas concretas, por projeto

Projeto 1 (ensaio CDISC) — perguntas de método estatístico, não de clínica

Pergunta	Métrica	Método	Armadilha
O efeito muda conforme a estratégia de evento intercorrente?	Diferença de médias (ou HR) por estratégia	ANCOVA / MMRM / modelo de sobrevivência, 4 estratégias	Comparar estratégias com p-values em vez de mostrar a divergência das estimativas
A análise primária é robusta a desvios de distribuição?	Mediana vs média, IC bootstrap	Bootstrap BCa, teste de permutação	Assumir normalidade em `ADAS-Cog` com n=254
O modelo misto é preferível ao ANCOVA?	AIC/BIC, estrutura de variância	MMRM com estrutura não-estruturada	Ignorar dados omissos não-MAR
A descontinuação é informativa?	Curva de sobrevivência da descontinuação	Kaplan-Meier de time-to-discontinuation	Tratar descontinuação como censura administrativa

Projeto 2 (OMOP de origem CDISC) — perguntas de epidemiologia clínica

Pergunta	Métrica	Método	Armadilha
Qual a incidência de eventos adversos emergentes de tratamento?	IR por 1.000 pessoas-ano, IC Poisson exato	Contagem de eventos / tempo em risco	**Misturar** `MH` **(história) com** `AE` **(emergente)** — ambos vivem em `CONDITION_OCCURRENCE` com o mesmo type concept 32809
Há sinal de hepatotoxicidade?	Quadrantes eDISH, Hy's Law (ALT>3×LSN e BT>2×LSN)	Rácio ALT vs BT no pico	Ignorar LSN (falta de referência) em vez de o declarar como limitação
A sobrevivência livre de evento difere entre braços?	KM, mediana, **RMST**	Log-rank, Cox, RMST (preferível com n pequeno e censura)	Reportar só HR quando os riscos não são proporcionais
O efeito varia com o tempo?	HR dependente do tempo	Schoenfeld residuals, modelo com interação tempo×braço	Assumir proporcionalidade sem testar

Sobre o RMST — vale a pena insistir. Com 25 doentes por braço e ~70 dias, a mediana de sobrevivência pode não ser atingida, e o HR assume proporcionalidade que não podes verificar. O **restricted mean survival time** (área sob a curva KM até τ) é uma métrica absoluta, interpretável em dias, e não exige proporcionalidade. É a escolha correta e quase ninguém a faz. Dizer "preferi RMST a HR porque com n=25 não posso verificar proporcionalidade" é uma frase de sénior.

Projeto 3 (EHR longitudinal) — perguntas de epidemiologia de dados reais

Pergunta	Métrica	Método	Armadilha
Quem tem a doença X e quando começa?	Incidência por pessoa-ano	Cascata de fenótipos com ≥1 ou ≥2 códigos, janela de washout	Definição de caso escolhida *post hoc*
Os doentes tomam a medicação?	PDC, MPR, persistência (gap ≤ 30/60/90d)	`DrugUtilisation`-style, KM de descontinuação	Janela de gap escolhida para maximizar o resultado
Há associação fármaco→evento?	IRR	SCCS, autocontrolado	Intervalos de observação dependentes do evento
O efeito é constante entre subgrupos?	HR por subgrupo + teste de interação	Modelos com interação, *forest plot*	Testar 12 subgrupos e reportar o que deu p<0.05
Quantos doentes têm multimorbilidade?	Índice de Charlson/Elixhauser	Mapeamento por `CONCEPT_ANCESTOR`	Usar códigos literais em vez de descendentes

3.3 O catálogo de métricas — o que tens de saber explicar e quando usar

Ocorrência

- **Taxa de incidência** = eventos / pessoa-tempo. IC por Poisson exato (Clopper-Pearson para proporções). *Usa quando* há seguimento variável.
- **Incidência cumulativa** (risco) = eventos / pessoas em risco no início. *Usa quando* queres risco absoluto a um horizonte definido.
- **Prevalência pontual vs periódica**. *Nunca* confundas com incidência — num EHR com 26 anos, a prevalência depende da janela.

Associação

- **RR / OR / HR / IRR / RD**. Regra de ouro: **OR ≈ RR só quando o desfecho é raro (<10%)**. Num desfecho frequente, o OR exagera — e dizer isto espontaneamente é um sinal de rigor.
- **NNT/NNH** — a métrica que os clínicos entendem e os estatísticos esquecem.
- **Fração atribuível** — para comunicação de saúde pública.

Sobrevivência

- KM + mediana + **RMST** + **risco competitivo (CIF)** com cause-specific e subdistribution HR. Em idosos com 26 anos de dados, a morte é sempre um risco competitivo e ignorá-lo sobrestima a incidência cumulativa.

Longitudinal

- MMRM, modelos mistos (intercepto e declive aleatórios), GEE (efeito populacional). **Bland-Altman** e **ICC(2,1)** para concordância — não correlação de Pearson.
- Decomposição within/between: separar "os doentes que têm valores altos" de "os doentes cujos valores sobem" é a diferença entre um modelo misto e uma regressão ingénua.

Adesão

- PDC, MPR, persistência, time-to-discontinuation, grace period.

Segurança

- IR por 1.000 pessoas-ano com IC exato; eDISH; Hy's Law; SMQ a nível de PT.
- **Não**: PRR/ROR em EHR de coorte (só fazem sentido em notificação espontânea).

Fenotipagem

- Sensibilidade, especificidade, VPP/VPN do algoritmo vs adjudicação; **κ de Cohen** (e PABAK quando a prevalência é extrema — κ colapsa com prevalência baixa, e há que o reconhecer).

Predição

- AUROC **e** AUPRC (em desfechos raros o AUROC engana), **calibração** (slope e intercept), Brier, decision curve analysis.

Sensibilidade a confundimento

- **E-value** (quão forte teria de ser o confundidor não medido para anular o efeito), análise de viés quantitativa, tipping point, controlos negativos.

Heterogeneidade federada

- I^2, τ^2, **intervalo de previsão** (não só IC da média), forest plot com pesos.

3.4 Os oito métodos que tens de explicar de cor, sem notas

- **New-user, active-comparator** — e porquê: evita viés de utilizador prevalente, depletion of susceptibles e confundimento por contraindicação.
- **Propensity score de larga escala** — milhares de covariáveis, regularização, avaliação por **SMD < 0.1** e love plot, nunca por p-value de balanceamento.
- **IPTW com pesos estabilizados e truncados** — e o que o truncagem faz ao viés vs variância.
- **Controlos negativos + calibração empírica** — a ideia de que um estudo sem distribuição nula conhecida não é interpretável. É o argumento mais forte contra "o meu p-value é 0.03".
- **SCCS com períodos de observação dependentes do evento** — a extensão que evita o viés de eventos que encurtam a janela de observação.
- **Target trial emulation com *clone-censor-weight*** — e a diferença entre intention-to-treat emulado e per-protocol emulado.
- **Múltipla imputação vs complete-case vs indicador de omissão** — e porque é que o indicador de omissão é quase sempre errado.
- **Riscos competitivos** — cause-specific vs subdistribution: a primeira responde "o efeito na taxa instantânea", a segunda "o efeito na incidência cumulativa". Confundi-las é o erro mais comum em análises de idosos.

3.5 O que não fazer com estes dados

- **Não** faças inferência comparativa com 25 doentes por braço. Nem com 58.
- **Não** publiques um AUROC sem calibração.
- **Não** uses `LIKE '%paracetamol%'`. Já está identificado no teu código (`rwe_queries.py`); corrige-o para concept set versionado com `CONCEPT_ANCESTOR`.
- **Não** reportes um `p<0.05` num teste de balanceamento de baseline.
- **Não** compares tabelas 1 com p-values entre estudos diferentes (a significância depende de N; o SMD não).
- **Não** apresentes descobertas clínicas a partir de dados sintéticos. Nem uma.
- **Não** faças 12 testes de subgrupo sem pré-especificação e sem correção.

PARTE IV — Q3: ESTRATÉGIA DE DADOS

4.1 O princípio central: os dados licenciam as afirmações

Esta é a ideia que organiza tudo o resto. Antes de escolher um dataset, pergunta: **que frase vou poder dizer no fim, e com que autoridade?**

Afirmação que queres fazer	Dados mínimos necessários
"O meu código corre e é reprodutível"	Sintético próprio
"O meu estimador recupera o parâmetro verdadeiro com cobertura de 95%"	Sintético **com verdade conhecida** (simulação plasmode)
"A minha conversão FHIR→OMOP está correta"	Fonte real **+ conversão de referência** (T1)
"A minha análise replica a análise regulatória"	ADaM de referência (T1)
"O meu pipeline sobrevive a dados reais sujos"	Dados reais abertos (T1)
"Este é um achado clínico"	Dados reais credenciados (T2)
"Este achado generaliza"	T2, multi-fonte, com heterogeneidade quantificada
"Isto sustenta uma decisão regulatória"	T2 + protocolo pré-registado + calibração + auditoria + DQD

A frase que mata 90% dos portefólios de RWE: apresentar uma conclusão clínica a partir de dados sintéticos. O avaliador sabe, em 10 segundos, que a conclusão é uma propriedade do gerador de dados e não do mundo. E a partir daí lê tudo o resto com suspeita.

A frase que salva o teu: dizer isso **antes** de te perguntarem. "Estes dados são sintéticos, portanto o que eles me permitem afirmar é que o meu estimador é válido — não que o fármaco funciona. Separei deliberadamente as duas coisas: o estudo de métodos corre aqui, o estudo clínico corre em MIMIC."

4.2 O portefólio de dados em quatro camadas

T0 — Sintético próprio (o que já tens)

50 doentes (ensaio) e 58 doentes (EHR).
Licencia: correção do código, reprodutibilidade, testes adversariais, verdade conhecida, privacidade total.
Custo: zero. Latência: imediata.
Limitação brutal: não contém nada sobre o mundo.

T1 — Aberto e real (ou quase) — é aqui que deves investir agora

Dataset	Acesso	Tamanho	O que licencia
CDISCPILOT01	GitHub `cdisc-org/sdtm-adam-pilot-project`	254 aleatorizados; SDTM+ADaM+`define.xml`	Replicação da análise regulatória; estimandos
MIMIC-IV Clinical Database Demo	PhysioNet, **aberto, sem credenciais**	100 doentes; versão relacional + **FHIR (v2.1.0) + OMOP**	Validação diferencial de ETL; robustez em dados reais
Eunomia / GiBleed	`OHDSI/Eunomia`	2.694 doentes, CDM 5.5	Testes de CI do pipeline HADES; pre-flight de estudos
SynPUF (DE-SynPUF) em OMOP	AWS Open Data Registry	1k / 100k / **2,33 M** doentes	Escala e desempenho de queries; benchmarks
Synthea	Open	~1 M doentes sintéticos, FHIR R4	Volume para testar o pipeline FHIR→OMOP

Nota sobre o SynPUF: o CMS construiu-o **quebrando deliberadamente as relações entre variáveis** para proteger os beneficiários. Consequência: findings clínicos a partir do SynPUF **não têm significado**. É excelente para método e escala, inútil para clínica. Saber isto e dizê-lo é um teste de literacia que muito poucos passam.

T2 — Credenciado, real — o próximo salto de credibilidade

Dataset	Acesso	Escala	O que licencia
MIMIC-IV v3.1	PhysioNet credenciado (CITI + DUA)	~300 mil+ doentes, UCI de um centro terciário	Epidemiologia clínica, segurança, predição
MIMIC-IV on FHIR v2.1	PhysioNet credenciado	315.460 doentes, ~5,84 M recursos, 24+6 perfis	**Testar o teu pipeline FHIR→OMOP a escala real**
MIMIC-IV-ED	PhysioNet credenciado	~425 mil episódios de urgência	Trajetórias agudas, adesão pós-alta
eICU-CRD	PhysioNet credenciado	~200 mil internamentos em 200+ UCI	**Multi-centro → heterogeneidade → sinergia com o desenho federado**
NHANES	Público	~10 mil/ ciclo, transversal	Prevalência populacional, fatores de risco
All of Us	Researcher Workbench	Centenas de milhares, diverso	Generalização, equidade

T3 — Licenciado (Optum, MarketScan, CPRD, TriNetX, IQVIA)

Sem acesso. Servem para **arquitetura**: desenhar as interfaces e as specs como se fosses correr nelas. Nunca finjas que tens.

4.3 Quando o sintético é superior — e não é um mal menor

Há cinco situações em que o sintético não é o plano B, é o plano A:

- **Verdade conhecida.** Só com dados gerados sabes o parâmetro verdadeiro. Se queres demonstrar que o teu estimador é válido — viés, cobertura, erro quadrático médio — precisas de sintético. **Não há alternativa.**
- **Testes adversariais.** Introduzir violações deliberadas: datas impossíveis, unidades trocadas, códigos órfãos, `concept_id = 0` misturado com `NULL`. Nos dados reais não escolhes os erros.
- **CI e reprodutibilidade.** Um teste que corre em 30 segundos com 50 doentes pode estar em cada commit. Um que exige uma DUA, não.
- **Casos-limite raros.** Queres testar o comportamento com 100% de abandono, ou com um só doente, ou com todos os valores nulos. Não encontras isso num dataset real.
- **Privacidade e partilha.** Podes publicar o dataset, o que significa que o revisor pode correr o teu código. Isso vale mais do que parece.

4.4 Quando precisas de real — e o que custa

Precisas de dados reais quando a afirmação envolve o mundo: epidemiologia, segurança, efetividade, predição, generalização. Não há como contornar.

O custo real, honestamente contabilizado:

- **MIMIC-IV demo:** 0 €, ~1 hora (download + carga em DuckDB). **O melhor retorno por hora de todo este plano.**
- **MIMIC-IV completo:** 0 €, mas exige PhysioNet credentialed access — formação CITI em proteção de participantes humanos, submissão de DUA, aprovação que pode levar dias a semanas. Deves **começar o processo hoje**, mesmo que só uses os dados dentro de dois meses.
- **MIMIC-IV on FHIR completo:** a mesma credencial, mais um download de vários GB em NDJSON.

Restrições que tens de respeitar e saber recitar: não redistribuir; não tentar re-identificar; usar apenas em ambiente controlado; citar corretamente; respeitar o âmbito do DUA. Violar isto termina a carreira de alguém, e num entrevista é uma pergunta de triagem.

4.5 ETL-through vs pré-mapeado: a regra de decisão

A pergunta que fizeste é excelente, e a resposta não é "depende" — é uma regra.

> **Se o ETL é a afirmação, passa os dados pelo teu pipeline. Se a análise é a afirmação, usa os dados pré-mapeados.**

E um corolário ainda mais importante:

> **Nunca passes semanas a mapear um dataset que já tem conversão oficial, para no fim correr uma regressão.**

Aplicando aos teus casos:

Situação	Escolha	Porquê
Queres provar que o teu pipeline FHIR→OMOP funciona	**ETL-through**: MIMIC-IV-on-FHIR → o teu pipeline	O ETL é a afirmação
Queres estudar informed presence em 26 anos de dados	**Pré-mapeado** (ou o teu Projeto B já mapeado)	A análise é a afirmação
Queres testar `CohortMethod`	**Pré-mapeado**: MIMIC-CDM, Eunomia	A metodologia é a afirmação
Queres um estudo clínico credível	**Pré-mapeado**: MIMIC-IV v3.1	O achado é a afirmação
Queres demonstrar rigor de ingestão ponta-a-ponta	**ETL-through**: CDISCPILOT01 raw → SDTM → ADaM	O ETL é a afirmação

★ 4.5.1 A proposta forte: VALIDAÇÃO DIFERENCIAL

Aqui está a jogada que eu faria primeiro, e que provavelmente ninguém no teu painel já viu.

O facto que torna isto possível: o MIMIC-IV Clinical Database Demo (100 doentes, derivado do MIMIC-IV Demo v2.2) existe em **três representações independentes**:

- **Relacional nativo** (`mimiciv_hosp`, `mimiciv_icu`)
- **FHIR R4** — 100 doentes, ~915 mil recursos, NDJSON, perfis MIMIC
- **OMOP CDM** — conversão do OHDSI (`OHDSI/MIMIC`), 100 doentes

Logo: podes pegar na representação **FHIR**, passá-la pelo teu pipeline FHIR→OMOP, e comparar o resultado com a **conversão de referência do OHDSI** — que partiu dos mesmos doentes mas por um caminho completamente diferente.

Isto não é uma validação contra o vazio. É uma validação contra um par. Duas implementações independentes do mesmo problema, comparadas doente a doente.

O que medes — sete métricas, definidas antes de correr:

#	Métrica	Como
1	**Cobertura de registos**	Linhas de origem → linhas mapeadas → não mapeadas, com razões
2	**Integridade referencial**	Órfãos em `*_occurrence`, `person_id` inexistente, visitas sem doente
3	**Concordância de conceito**	Por domínio: % de `*_concept_id` iguais; **κ de Cohen**; matriz de confusão dos top-20 conceitos
4	**Concordância de valores**	`value_as_number` e `unit_concept_id`: viés médio e limites de concordância de Bland-Altman
5	**Concordância temporal**	Diferença em dias entre datas equivalentes; % dentro de ±1 dia
6	**DQD lado a lado**	Mesmos checks, dois CDMs, taxa de aprovação comparada
7	**Atrição por domínio**	Quantos doentes ficam com pelo menos um registo em cada tabela

O entregável: um relatório com uma tabela de concordância por domínio, um heatmap de discordância de conceitos, e uma **lista de causas-raiz das divergências** — que é a parte mais valiosa, porque revela decisões de modelação, não bugs.

Exemplos do tipo de achado que vais encontrar, e do que ele significa:

- O FHIR não impõe uma representação única para "medicação administrada" vs "prescrita". O teu pipeline pode mapear `MedicationAdministration` para `DRUG_EXPOSURE`, enquanto a referência mapeia `MedicationRequest`. **Nenhum está errado** — são semânticas diferentes. Documentar isto é ouro, porque é exatamente o problema que a Promptly, a EHDEN e a DARWIN EU enfrentam a cada novo parceiro de dados.
- Unidades: o FHIR transporta `Quantity` com `unit` e `code`; o OMOP exige `unit_concept_id`. Uma unidade não mapeada produz `unit_concept_id = 0`. Quantos? Isso é uma métrica de qualidade, não um detalhe.
- Datas: `Encounter.period` vs `VISIT_OCCURRENCE.visit_start_date`. Fuso horário, granularidade, valores nulos.

Porque é que isto vale mais do que qualquer outro estudo do portefólio:

- Prova **engenharia medida** — não "construí", mas "medi a correção da construção".
- É replicável por qualquer pessoa (dados abertos) — logo, é verificável.
- É **publicável** no simpósio europeu do OHDSI. Há espaço real para um methods abstract sobre validação diferencial de conversões.
- Fala diretamente à dor comercial de uma rede federada: "como sei eu que o ETL do novo parceiro é bom?" — a resposta é: comparando contra uma referência quando existe, e contra um perfil esperado quando não existe.

Tempo estimado: 2 a 3 fins de semana. **Custo:** zero. **Risco:** baixo.

4.5.2 O segundo uso: validar o Projeto 1 contra um gabarito

O mesmo padrão aplica-se ao CDISC: pega no `CDISCPILOT01`, corre **o teu pipeline raw→SDTM→ADaM**, e compara com os ADaM oficiais. Métricas: contagem de linhas por dataset, igualdade variável a variável, e — o mais interessante — **% de valores derivados que coincidem**.

Aqui há um detalhe que deves antecipar: **vais divergir**, e as divergências são o conteúdo. Um ADSL oficial tem decisões de população de análise (quem é `SAFFL`, quem é `ITTFL`, como se tratam os screen failures — 306 rastreados, 254 aleatorizados). Se o teu pipeline produzir 306 no ADSL e o oficial 254, não é um bug: é uma diferença de definição de população. **Documentar isso é mais valioso do que acertar à primeira.**

4.6 A rede federada num só portátil

Esta é a segunda ideia original, e a que tem mais potencial de conversa em entrevista.

O problema. Ninguém te vai dar acesso a uma rede federada para tu aprenderes. Mas quase toda a gente te vai perguntar: "já trabalhaste em ambiente federado?"

A solução. Simula-a. Os teus 58 doentes fragmentam-se em 3 "nós" por `hash(subject_id)`, com sobreposição de perfis de doente deliberadamente diferente entre nós (para criar heterogeneidade realista).

Depois:

- Escreve o estudo como uma **spec declarativa em JSON** — cohorts (Circe), janelas, análises, covariáveis, método de ajuste. Formato inspirado no `Strategus`.
- Corre a mesma spec em cada nó, localmente em DuckDB, sem que nenhum nó veja os dados dos outros.
- Agrega os **resultados sumariais** com meta-análise (`EvidenceSynthesis` ou implementação própria): efeito por nó, I^2, τ^2, **intervalo de previsão**, forest plot.
- Mostra que o código é **literalmente o mesmo nos três nós** — só muda a connection string.

O que isto demonstra, e porque é exatamente o que a DARWIN EU compra: a única coisa que viaja entre nós é o **código** e os **resultados agregados**. A mediana de 4,8 meses protocolo→resultado da DARWIN EU só é possível porque o estudo é uma spec e não um script artesanal. Mostrar que sabes estruturar um estudo assim — mesmo sobre 58 doentes — é mostrar que entendes o modelo operacional.

E há um bónus: podes usar o eICU-CRD como "multi-centro real" mais tarde (200+ UCI, um só credential), o que dá heterogeneidade genuína em vez de simulada. Aí a demonstração passa de metáfora a dados.

4.7 Considerações que não são burocracia

- **PhysioNet:** começa o processo de credenciação **esta semana**. CITI training + DUA. Não custa dinheiro, custa tempo de calendário, e é o único passo que te separa de MIMIC completo.
- **Não redistribuas** MIMIC em nenhum repositório público. Mantém os dados fora do Git (o teu repo já ignora `data/`? Confirma), e versiona apenas o **código** e os **resultados agregados**.
- **Cita corretamente** (DOI de versão), porque os revisores verificam.
- **Mostra o** `cdm_source` de cada base de dados no relatório: nome, versão do CDM, versão do vocabulário, data de release. É o equivalente ao "materials and methods" dos dados.
- **Regista o teu** `vocabulary_signature`**.** O teu repo já tem uma função que calcula um sha256 sobre a versão do schema, os vocabulários, a contagem e o intervalo de `concept_id`, e um `BIT_XOR(HASH(...))`. **Isto é raro e é um diferenciador real**: quase nenhum estudo OMOP liga os resultados a uma assinatura de vocabulário. Usa-o em todos os relatórios.

4.8 O programa de aquisição de dados em 90 dias

Semana	Ação	Entregável
1	Iniciar credenciação PhysioNet (CITI + DUA)	Submissão feita
1	Descarregar MIMIC-IV Demo (relacional + FHIR + OMOP)	Três CDMs locais em DuckDB
2–4	**X1 — Validação diferencial**	Relatório #1
3	Descarregar CDISCPILOT01	SDTM/ADaM em DuckDB/Parquet
5–6	**P1.1 — Estimand Lab**	Relatório #2
7–8	**P2.4 — Custo do RWD**	Relatório #3
7	Credenciação MIMIC completo (se aprovada)	Acesso a v3.1 + FHIR + eICU
9–10	**P3.3 — Informed presence**	Relatório #4
11	**X2 — Rede federada num portátil**	Demo + forest plot
12	Consolidação: site, README, 4 vídeos de 90s	Portefólio

Nota: as semanas 2–10 assumem trabalho paralelo. Se só tiveres ~10 horas por semana, isto é um plano de 5–6 meses, não de 3. Sê honesto contigo sobre a capacidade — um estudo terminado vale mais do que quatro a meio.

PARTE V — Q4: COMO APRESENTAR PARA DEMONSTRAR RIGOR DE NÍVEL MUNDIAL

5.1 A unidade de entrega é o pacote de estudo, não o notebook

Um notebook responde a "o que fizeste?". Um pacote de estudo responde a "posso confiar nisto, e posso correr noutro sítio?".

A diferença não é estética. É a diferença entre um artefacto que alguém **audita** e um artefacto que alguém **lê**.

5.2 A anatomia de um pacote de estudo

```
study_<nome>/
├── README.md                    # 1 página: pergunta, dados, resultado principal, como correr
├── protocol/
│   ├── protocol.md              # pré-especificado, datado
│   ├── estimand.md              # 5 atributos ICH E9(R1)
│   └── sap.md                   # análise primária, secundárias, sensibilidade
├── cohorts/
│   ├── *.json                   # Circe / concept sets, versionados
│   └── manifest.csv             # id, nome, racional, versão
├── sql/
│   ├── 00_cdm_checks.sql
│   ├── 10_cohorts.sql
│   ├── 20_attrition.sql
│   └── 30_analysis.sql
├── src/                         # orquestração (R ou Python)
├── results/
│   ├── attrition.csv
│   ├── table1.csv
│   ├── estimates.csv
│   └── diagnostics/
├── reports/
│   ├── report.md / .html / .pdf
│   └── figures/
├── logs/
│   └── analysis_log.md          # decisões, tentativas abandonadas, motivos
├── manifest.json                # versões, hashes, vocabulary_signature, tempo
└── tests/
```

Três coisas neste layout que quase ninguém tem e que valem muito:

`protocol/` **preenchido antes de correr a análise.** Isto é o artefacto mais impressionante de todos. Um protocolo de 2–3 páginas, datado, com hipótese, estimando, análise primária, análises de sensibilidade e — a parte que ninguém faz — uma secção **"o que me faria abandonar esta análise"**. Se o resultado violar essa condição, tens de o reportar. Isso é a marca de quem não está a fazer p-hacking.

`logs/analysis_log.md`**.** Um registo de decisões: "testei a janela de washout a 90, 180 e 365 dias; escolhi 180 porque X; a 90 o N caía para 12 e o IC tornava-se ininterpretável". Isto é o que separa uma análise honesta de uma análise que parece honesta. E é extraordinariamente raro.

`manifest.json` **com** `vocabulary_signature`**.** Liga o resultado a um estado exato do vocabulário. É a única forma de garantir que o estudo é reproduzível daqui a dois anos, quando o Athena publicar outra versão.

5.3 Os seis artefactos que separam amador de profissional

#	Artefacto	O que prova	Como falha o amador
1	**Protocolo pré-especificado datado**	Não fizeste p-hacking	Analisa primeiro, escreve depois
2	**Tabela de atrição por passo**	Sabes exatamente quem entrou e quem saiu	Reporta só o N final
3	**Tabela 1 com SMD + love plot**	Sabes avaliar confundimento	Usa p-values, que dependem do N
4	**Controlos negativos + calibração**	Sabes avaliar se o teu estudo é interpretável	Reporta o p-value como se fosse prova
5	**Análises de sensibilidade + E-value**	Sabes o que te pode derrubar	Uma análise, um resultado
6	**Manifesto de reprodutibilidade**	Alguém pode correr isto	"Funciona na minha máquina"

Sobre o #3, com precisão. O **SMD** (diferença de médias padronizada) não depende do tamanho da amostra. Isso tem duas consequências: (a) não fica "significativo" só porque tens 2 milhões de doentes — como acontece com os p-values em estudos de claims; (b) **é comparável entre nós de uma rede federada**, porque um nó com 50 mil doentes e outro com 5 milhões produzem o mesmo SMD para o mesmo desequilíbrio. Num contexto federado, o SMD não é só melhor — é a **única** métrica de balanceamento que viaja. Dizer isto numa entrevista é um sinal forte.

Sobre o #4, com precisão. Um estudo observacional sem distribuição nula conhecida não é interpretável, porque não sabes se o teu método produz falsos positivos naquele dataset. Os controlos negativos dão-te essa distribuição: escolhes desfechos onde sabes que o efeito é nulo, estimas, e verificas se a tua distribuição de p-values é uniforme. Se não for, calibras empiricamente. E podes reportar **o erro sistemático e o erro de aleatorização** estimados (as duas componentes que a `EmpiricalCalibration` separa). Isto é o padrão-ouro do OHDSI e é o que distingue um estudo que parece rigoroso de um que é rigoroso.

5.4 A estrutura do relatório — as doze secções que um revisor espera

- **Título + registo** (onde está pré-registado, data, versão do protocolo)
- **Resumo em linguagem simples** (5 frases, sem jargão, sem números)
- **Contexto e racional** (porque é que esta pergunta importa clinicamente)
- **Objetivos e estimando** (população, exposição, comparador, desfecho, eventos intercorrentes, medida sumária)
- **Fonte de dados e proveniência** (CDM, versão, vocabulário + assinatura, DQD sumário, limitações conhecidas da fonte)
- **Construção da coorte e atrição** (C1 → C2 → C3 → C4 com N em cada passo)
- **Métodos** (desenho, confundimento, omissão, riscos competitivos, sensibilidade)
- **Resultados** (Tabela 1 com SMD; resultado primário; secundários)
- **Diagnósticos** (controlos negativos, calibração, balanceamento, proporcionalidade)
- **Sensibilidade** (análise principal replicada sob cada decisão contestável, + E-value)
- **Discussão e limites** (ROBINS-I domínio a domínio; o que este estudo **não** pode dizer)
- **Apêndice de reprodutibilidade** (versões, hashes, tempo de execução, como correr)

Uma regra de ouro para a secção 11: escreve tu a crítica mais dura que consegues imaginar ao teu próprio estudo, e responde-lhe. Se um revisor encontrar uma crítica que tu não antecipaste, perdeste. Se encontrar todas e tu já as respondeste, ganhaste — mesmo que o resultado seja fraco.

5.5 O mapa de standards — mostra que sabes qual se aplica a quê

Norma	Aplica-se a	Onde no relatório
STROBE	Estudos observacionais	Estrutura geral
RECORD	Dados de saúde recolhidos rotineiramente	Proveniência, linkage, código de fenótipos
RECORD-PE	Farmacoepidemiologia	Definição de exposição, janelas, confundimento
GRACE	Boas práticas em RWE	Checklist de qualidade do estudo
HARPER	RWE em decisão de saúde	Transparência e reprodutibilidade
ROBINS-I	Risco de viés em estudos não aleatorizados	Secção 11
ICH E9(R1)	Definição do estimando	Secção 4 e protocolo
TRIPOD+AI / PROBAST+AI	Modelos preditivos (se algum dia)	Modelo e validação
ENCEPP	Protocolo de estudo pós-autorização (UE)	Modelo de protocolo
CDISC SDTM/ADaM/Define-XML	Projeto 1	Todo

Não cites todos em todos os estudos. Cita os que se aplicam, e diz porquê. Um relatório que invoca sete standards parece inseguro; um que invoca dois, com justificação, parece competente.

5.6 A estratégia de prova pública

Ordem de importância, do mais para o menos impactante:

- **Quatro relatórios de estudo completos, cada um com uma página de resumo** — legíveis em 10 minutos cada.
- **Os repositórios**, com o README a dizer em três linhas qual é a pergunta e qual é o resultado principal.
- **Quatro vídeos de 90 segundos** — um por estudo, ecrã + voz, a explicar a pergunta, o método e o resultado. Isto é desproporcionadamente eficaz: um Lead vê 90 segundos, quase nunca lê um relatório de 20 páginas.
- **Uma página de portefólio** que diz: que músculo cada estudo prova.
- **Um methods abstract** submetido ao simpósio europeu do OHDSI (validação diferencial ou informed presence). Mesmo que não seja aceite, o processo força-te a escrever para revisores — e um "submetido" no CV é verificável.

O que NÃO fazer: um repositório com 40 notebooks sem README, chamado "RWE-Playground". Isso transmite o oposto de rigor: transmite entusiasmo sem direção, e um Lead lê isso como "vai levar 6 meses a produzir algo que eu possa mostrar a um cliente".

5.7 O pitch de 90 segundos — template

> **Pergunta.** "O estudo X pergunta [pergunta clínica em uma frase]."
> **Porquê.** "Importa porque [consequência clínica ou regulatória]."
> **Dados.** "[Fonte], [N], [seguimento], CDM [versão], vocabulário [versão + assinatura]."
> **Desenho.** "[New-user / SCCS / TTE], com [ajuste]. O estimando é [5 atributos em 1 frase]."
> **Resultado.** "[Estimativa] ([IC 95%])."
> **Rigor.** "Antes de olhar para o resultado, pré-especifiquei [X]. Corri [N] controlos negativos; a calibração mostrou [Y]. A análise não sobrevive a um confundidor de [E-value], o que é [plausível/não plausível] porque [razão]."
> **Limite.** "O que isto **não** pode dizer é [limitação]. E é por isso que o próximo passo seria [Z]."

A parte que ganha é a última. Candidatos falam do que fizeram; seniores falam do que os seus resultados não provam.

5.8 Anti-padrões que destroem credibilidade

- **"Estatisticamente significativo"** sem estimativa e IC. (E nunca "ns".)
- **AUROC sem calibração.**
- **p-value num teste de balanceamento.**
- **Conclusão clínica a partir de sintético.**
- **"Correlação de Pearson" para concordância** — devia ser ICC ou Bland-Altman.
- **Fenotipagem por** `LIKE '%...%'` em vez de concept sets.
- **Misturar** `concept_id = 0` **com** `NULL` (o teu repo já distingue — mantém).
- **Nenhuma menção a confundimento não medido.**
- **Gráficos com eixos truncados, 3D, ou pie charts com 12 fatias.**
- **Um "pipeline" que só corre na tua máquina.**
- **Dizer "usei IA" sem dizer para quê, com que validação e com que taxa de erro.**

PARTE VI — PLANO DE 12 SEMANAS

Assumindo ~10–12 h/semana. Cada semana termina num artefacto verificável, não numa intenção.

Semana	Foco	Entregável concreto
0	Credenciação PhysioNet + downloads	MIMIC Demo (3 formas) e CDISCPILOT01 em DuckDB
1	Template do pacote de estudo + `manifest.json` + `analysis_log.md`	Template reutilizável, testado num estudo vazio
2	X1: carregar FHIR demo, correr o teu pipeline	OMOP próprio a partir de FHIR, com DQD
3	X1: comparação com o OMOP de referência	Tabela das 7 métricas
4	X1: causas-raiz + relatório	**Relatório #1** + abstract OHDSI
5	P1.1: definir evento intercorrente em DS/AE	Especificação escrita do estimando
6	P1.1: 4 estratégias + IC bootstrap + relatório	**Relatório #2**
7	P2.4: construir os degraus D0–D6	Código parametrizado por degrau
8	P2.4: 200 réplicas + viés e cobertura	**Relatório #3** com forest plot da escada
9	P3.3: modelo de intensidade de visita	Perfil de observabilidade
10	P3.3: ingénuo vs IIW vs outputation	**Relatório #4**
11	X2: fragmentação + spec JSON + síntese	Demo federada + forest plot
12	Consolidação	Site, README, 4 vídeos de 90s, CV atualizado

Pontos de decisão: se na semana 4 o X1 estiver atrasado, **corta o P1.1 para metade** em vez de cortar o X1. A validação diferencial é a peça mais rara e mais difícil de replicar por outro candidato.

PARTE VII — POSICIONAMENTO DE MERCADO

7.1 A frase

> **"Construo e valido a camada analítica que transforma um nó OMOP num estudo auditável — e consigo provar que a conversão que está por baixo não está a mentir."**

Repara no que ela faz: não diz "sei SQL" nem "sei OMOP". Diz que resolves um problema que quem contrata tem e não consegue resolver. Toda a gente sabe fazer ETL; quase ninguém sabe **medir se o ETL está certo** e **transformá-lo num estudo que aguenta revisão**.

7.2 Os arquétipos de empregador, e o que cada um compra

Arquétipo	Exemplos ilustrativos	O que compra	Qual dos teus estudos é a prova
Rede federada / data partner	Promptly, nós EHDEN, centros DARWIN EU	Portabilidade, governação, DQD, mapeamento de vocabulário	**X1** + **X2**
Software/analytics de RWE	Aetion, TriNetX, COTA	Velocidade, replicabilidade, pensamento de produto	**X1** + **P3.8**
Consultoria a pharma / HTA	IQVIA, Parexel, Certara, Putnam	Estimandos, prontidão para JCA, disciplina de TLF	**P1.1** + **P2.4**
CRO / statistical programming	ICON, Syneos, Fortrea	CDISC, dupla programação, `define.xml`	**P1.2** + **P1.4**
Payers / HTA / regulador	NICE, AIFA, EMA	Análise de viés, calibração, incerteza	**P2.4** + **P3.3**

A implicação estratégica: não podes otimizar para os cinco. O teu perfil atual (três pipelines + vocabulário governado + DQD) está mais próximo do **primeiro** arquétipo. Os estudos X1/X2/P3.3 consolidam essa posição. O P1.1 e o P2.4 dão-te opcionalidade para o terceiro — que é onde estão os salários mais altos e a barreira de entrada mais alta.

7.3 Porque é que a janela está aberta agora

Três pressões de mercado que estão a criar exatamente a procura que tu podes servir:

- **A JCA europeia exige submissão em 100 dias.** Isso mata estudos artesanais. Só sobrevive quem tem specs e pipelines reutilizáveis.
- **O EHDS vai multiplicar o número de nós de dados.** Cada novo nó é um problema de onboarding — e onboarding é exatamente mapeamento de vocabulário + DQD + validação. O OHDSI/UMC fez isso em 5 dias com `Strategus`; esse é o novo benchmark.
- **A FDA deixou de exigir dados individuais identificáveis** (dezembro de 2025). Isso torna a evidência federada e des-identificada submetível. A arquitetura que construíste passa de "academicamente elegante" a "comercialmente necessária".

7.4 O que o teu portefólio tem de provar a cada entrevistador

Em 60 segundos, o teu interlocutor quer responder a três perguntas silenciosas:

- **"Ele sabe o que é um estimando?"** → P1.1
- **"Ele sabe quando os dados o estão a enganar?"** → P2.4 + P3.3
- **"Ele consegue medir a qualidade da sua própria engenharia?"** → X1

Se as três respostas forem sim, o resto é negociação.

PARTE VIII — RISCOS, TRADE-OFFS, E O QUE EU CORTARIA

8.1 Os riscos reais

Risco	Probabilidade	Mitigação
Dispersão — cinco estudos a 60%	**Alta**	Regra dos quatro. Nada de começar o #5 antes de fechar o #4
X1 revelar que o teu pipeline tem falhas grandes	Média	É o ponto. Um relatório que encontra e corrige 6 divergências vale mais do que um que diz "0 divergências" (que ninguém acredita)
Credenciação PhysioNet atrasar	Média	Todo o plano T1 funciona sem ela. Só o P3.10 e o eICU dependem

Risco	Probabilidade	Mitigação
P3.3 produzir estimativas ininterpretáveis com n=58	**Alta**	Enquadra como estudo de viabilidade; o entregável é o procedimento, não o número
P2.4 consumir mais tempo do que previsto	Média	Começa por D0–D3 (os quatro degraus que importam); D4–D6 são extensões
Sobreposição com o dossiê anterior	Baixa	O dossiê é referência teórica; isto é execução. Não os fundas num só documento

8.2 O que eu cortaria, com justificação

- **P1.3 (TLF completo)** — cortaria para apêndice. É competência de CRO, não de RWE, e consome semanas.
- **P3.10 (predição)** — adiaria até ter MIMIC completo. Com 58 doentes é contraproducente.
- **P1.4 (`define.xml` completo)** — faria a versão mínima. O sinal já é dado pelo `sdtmchecks`; o benefício marginal é baixo.
- **VBHC / PROMs (B8 do dossiê)** — cortaria por agora. Sem dados de PROMs, é conversa. Retoma quando tiveres uma fonte.
- **Qualquer estudo sobre Kaggle** — cortaria. Datasets de proveniência desconhecida não sobrevivem à primeira pergunta séria ("de onde vêm estes doentes?"), e a proveniência é precisamente o produto que estás a vender.

8.3 As três decisões que eu tomaria hoje

- **Iniciar a credenciação PhysioNet hoje.** É o único item com latência de calendário e custo zero.
- **Descarregar os três MIMIC Demo e o CDISCPILOT01 hoje.** Em duas horas tens a matéria-prima de dois dos quatro estudos-bandeira.
- **Escrever o protocolo do X1 antes de tocar no código.** Se não conseguires escrever o protocolo, o estudo não está suficientemente bem definido para o começares — e essa é a lição que o próprio protocolo existe para te dar.

8.4 A frase final

O teu portefólio atual diz: "sei construir a infraestrutura".
O portefólio que este documento descreve diz: "sei o que a infraestrutura vale, quanto erra, e como provar isso a um revisor."

A distância entre as duas frases não é mais código. É **protocolo, atrição, diagnóstico e sensibilidade** — quatro coisas que custam pouco e que quase ninguém faz.

APÊNDICE A — RUNBOOK DE ACESSO AOS DADOS

```
# 1. CDISC Pilot 01 (público, sem registo)
git clone --depth 1 https://github.com/cdisc-org/sdtm-adam-pilot-project.git
#   SDTM: updated-pilot-submission-package/900172/m5/datasets/cdiscpilot01/tabulations/sdtm
#   ADaM: updated-pilot-submission-package/900172/m5/datasets/cdiscpilot01/analysis/adam/datasets
#   define.xml em ambas as camadas

# 2. MIMIC-IV Clinical Database Demo (aberto, sem credenciais)
#    Relacional:  https://physionet.org/content/mimiciv-demo/
#    FHIR:        https://physionet.org/content/mimic-iv-fhir-demo/2.1.0/
#    OMOP:        https://physionet.org/content/mimic-iv-demo-omop/0.9/

# 3. Eunomia (DuckDB, instantâneo)
#    install.packages("Eunomia")  |  CDMConnector::eunomiaDir()

# 4. SynPUF em OMOP (1k / 100k / 2.33M)
#    AWS Open Data Registry: cmsdesynpuf-omop

# 5. MIMIC-IV completo — requer credenciação
#    https://physionet.org/content/mimiciv/3.1/
#    Pré-requisito: CITI "Data or Specimens Only Research" + DUA
```

Carga em DuckDB (exemplo):

```
INSTALL duckdb; LOAD duckdb;
CREATE TABLE person AS SELECT * FROM read_csv_auto('.../person.csv');
-- ou, para NDJSON FHIR, carregar e achatar com json_extract
```

APÊNDICE B — PACOTES POR CAMADA

Camada	R	Python
Ligação ao CDM	`CDMConnector`, `omopgenerics`	`sqlalchemy` + DuckDB
Coortes	`CohortGenerator`, `CapR`, `CirceR`	SQL / `polars`
Caracterização	`Characterization`, `CohortCharacteristics`, `DrugUtilisation`	—
Incidência/prevalência	`IncidencePrevalence`, `CohortIncidence`	—
Estimação causal	`CohortMethod`, `SelfControlledCaseSeries`	`DoWhy`, `EconML`
Síntese	`EvidenceSynthesis`	`statsmodels`
Diagnóstico	`CohortDiagnostics`, `PhenotypeR`, `DataQualityDashboard`	—
Sobrevivência	`survival`, `riskRegression`, `cmprsk`	`lifelines`
Modelos mistos	`lme4`, `nlme`, `mmrm`	`statsmodels` MixedLM
TLF	`rtables`, `chevron`, `gtsummary`, `cards`	`tableone`
ADaM/SDTM	`admiral`, `metacore`, `xportr`, `sdtmchecks`	—

APÊNDICE C — MODELO DE UM CONCEPT SET VERSIONADO

```
{
  "id": "cs_alt_elevation_v1",
  "name": "Elevated ALT (any descendant)",
  "version": "1.0.0",
  "domains": ["Measurement"],
  "includeDescendants": true,
  "includeMapped": false,
  "exclude": [],
  "concepts": [
    {"concept_id": 3013721, "concept_name": "Alanine aminotransferase [Enzymatic activity/volume]
    in Serum or Plasma",
     "vocabulary_id": "LOINC", "include_descendants": true, "include_mapped": false}
  ],
  "notes": "Não atravessar vocabulários. Respeitar min/max_levels_of_separation quando aplicável.
    SELECT DISTINCT obrigatório com CONCEPT_ANCESTOR."
}
```

APÊNDICE D — CHECKLIST DE PRÉ-REGISTO

- [ ] Pergunta em uma frase, com população, exposição, comparador, desfecho
- [ ] Estimando completo (5 atributos ICH E9(R1))
- [ ] Análise primária, com o modelo escrito por extenso
- [ ] Análises secundárias (lista fechada)
- [ ] Análises de sensibilidade (lista fechada)
- [ ] Poder/precisão **declarados a priori** — ou a assunção de que é exploratório
- [ ] Definição da janela de washout, do time zero, do tempo em risco
- [ ] Definição do tratamento da omissão
- [ ] Definição do tratamento de riscos competitivos
- [ ] Controlos negativos (quais, e porque são negativos)
- [ ] **"O que me faria abandonar esta análise"**
- [ ] Data e versão do protocolo

APÊNDICE E — FONTES

Regulamentação

- FDA, Use of Real-World Evidence to Support Regulatory Decision-Making for Medical Devices, orientação final, 18 dez 2025 (supersede a de 2017; implementação 17 fev 2026) — `fda.gov/media/190201`
- FDA, comunicado de 15 dez 2025 sobre aceitação de RWE sem dados individuais identificáveis — `fda.gov/news-events/press-announcements`
- Regulamento (UE) 2021/2282 (HTA); HTACG Annual Work Programme 2026; primeira JCA aprovada 30 abr 2026 (tovorafenibe), primeiro relatório publicado 9 jun 2026 — `health.ec.europa.eu`
- Regulamento (UE) 2025/327 (EHDS): em vigor 26 mar 2025; aplicação geral 26 mar 2027; uso secundário 26 mar 2029; ensaios/genómica 26 mar 2031 — `health.ec.europa.eu`
- EMA, Real-world evidence framework to support EU regulatory decision-making — 4.º relatório (8 fev 2025 – 7 fev 2026): 108 tópicos, 88 estudos, mediana 4,8 meses, parceiros 3→6, viabilidade ~78–80%

Dados

- CDISC SDTM/ADaM Pilot Project (`cdisc-org/sdtm-adam-pilot-project`): 306 rastreados, 254 aleatorizados, xanomelina, ADAS-Cog(11) à semana 24
- MIMIC-IV — `physionet.org/content/mimiciv/3.1/`; demo aberto `mimiciv-demo`
- MIMIC-IV on FHIR v2.1 — 315.460 doentes, ~5,84 M recursos; demo 2.1.0 com 100 doentes e ~915 mil recursos — `physionet.org/content/mimic-iv-fhir/2.1/`
- MIMIC-IV Demo em OMOP CDM (OHDSI/MIMIC), CDM 5.3.1, 100 doentes — `physionet.org/content/mimic-iv-demo-omop/0.9/`
- `CogStack/dbt_mimic_omop` — pipeline dbt+DuckDB para MIMIC-IV→OMOP 5.4; BIONLP 2026, `aclanthology.org/2026.bionlp-1.80`

- Eunomia / GiBleed (2.694 doentes, CDM 5.5); DE-SynPUF 1k/100k/2,33 M em OMOP (AWS Open Data Registry)

Métodos e tooling

- OHDSI HADES: `CohortMethod` 6.0.1 (CRAN, mar 2026), `Strategus` 1.5.x, `EvidenceSynthesis`, `CohortDiagnostics` — `ohdsi.github.io/Hades`
- OHDSI + Uppsala Monitoring Centre: estudo completo com `Strategus` em 5 dias sobre registos suecos — `ohdsi.org/community-calls-2026`
- Electronic Health Records in Epidemiology: Appropriate Questions, Common Biases, and Potential Sensitivity Analyses — `Springer, Curr Epidemiol Rep, 2025`
- Informed presence in electronic health record data: illustrating bias and bias reduction approaches in longitudinal analyses (2026): IRR 1,83 (1,02–3,28) → 1,37 (0,73–2,57) com inverse intensity weighting — `PubMed 41849238`
- Mitigating bias in the analysis and inferences from using longitudinal EHR data (2026): número de registos de peso como preditor mais forte de 10 desfechos cardiovasculares — `BMC Med Res Methodol`
- Informative presence bias in analyses of EHR-derived data: a cautionary note — `PMC9196698`

Documento complementar a `RWE_ANALYTICS_DOSSIER.md` (métodos estudo-a-estudo dos Projetos A e B) e a `PROMPTLY_HEALTH_INTERVIEW_PREP.md` (preparação de entrevista).